

非受限条件下的眨眼检测方法的研究

——眼部定位裁剪与眨眼检测两级分离设计

2026 年 7 月

总设计：眼部定位裁剪与眨眼检测两级分离设计

本研究针对非受限条件下的眨眼检测任务，采用“眼部定位裁剪+眨眼检测”两级分离的系统设计架构。该设计将整个眨眼检测流程分解为两个相对独立的阶段：第一阶段为人脸检测与眼部定位，负责从原始视频帧中检测人脸并精确裁剪出眼部区域；第二阶段为眨眼检测，基于裁剪出的眼部帧序列进行时序建模，判断是否存在眨眼事件。这种两级分离设计的核心优势在于：各阶段可独立优化，模块化程度高，便于针对不同阶段的任务特性选择最适合的算法方案。

在第一阶段（人脸检测和眼部定位），本研究比较了 RT-DETRv2、MediaPipe Face Landmarker 和 YOLOv8-Nano 三种候选架构，并进一步对 YOLOv8-Nano 进行了系统性的超参数调优实验。在第二阶段（眨眼检测），本研究提出了基于双向多尺度状态空间模型（BiMamba）的核心创新方法，同时复现对比了 MS-LSTM、BiLSTM+Attention、差分特征+Focal Loss、A-Softmax 集成以及 BlinkFormer-Transformer 等多种现有方法。通过两级分离设计，本研究在非受限场景下实现了高精度、高鲁棒性的眨眼检测。

第一章 人脸检测和眼部定位方法设计

第一节 方法设计

一、实验背景与任务定义

1.1 项目背景

人眼检测与定位是计算机视觉的基础任务，用于人脸识别、疲劳驾驶检测、视线追踪等场景。准确地从视频帧中裁剪出人眼区域，是后续眨眼检测的前提条件。

DeFB (Decomposed Feature Learning for Eyeblink Detection) 是发表于 AAAI 2026 的多人实时眨眼检测算法。该方法将人脸定位和眼部特征建模分解到不同的特征空间中，实现细粒度时空建模。在 MPEblink 上 Blink-AP 达到 24.65% (此前 InstBlink 仅 10.11%)，推理效率提升约 35%。

本报告针对 DeFB 的 Task 1——人眼定位网络设计阶段。目标是从 1280x720 帧中裁剪左右眼区域，输出 64x64 单眼图像，作为 Stage 2 眨眼检测模块的输入。

1.2 任务定义

项目	规格
输入	1280×720 视频帧 (JPEG 序列)
输出	左右眼独立 64×64 裁剪
窗口长度	13 帧连续序列 (滑动窗口选取最佳窗口)
输出格式	PNG 图片 + NumPy 数组 [13, 64, 64, 3] uint8
检测目标	左眼 (class 0) / 右眼 (class 1)
评价指标	检测成功率 (%) + Laplacian sharpness
输出目录结构	{video_id}/eye_001/(左眼), eye_002/(右眼)

1.3 候选方案总览

实验比较了三种候选架构：

方案	架构	参数量	核心原理	训练要求	来源
A	RT-DETRv2 Lite	21.8M	Transformer 端到端检测 (DETR 系列)	需 100+ epoch	百度
A2	RT-DETRv2	2.6M	Transformer +	需 100+	百度

	Nano		MobileNetV3	epoch	
B	MediaPipe Face Landmarker	~3M	478 点 face mesh 眼周轮 廓	零训练	Google
C	YOLOv8-Nano	3.0M	Anchor-free CNN 单阶段检 测	100 epoch	Ultralytics

三者在参数量、训练原理和检测方式上有明显差异：

方案 A 代表端到端 Transformer 检测器路线，参数量跨度大（2.6M~21.8M）

方案 B 代表预训练模型零训练路线，无需训练成本

方案 C 代表轻量级 CNN 检测器路线，在参数量和性能之间取得平衡

1.4 实验环境与评价指标

硬件环境

组件	规格
GPU	NVIDIA A10 (22716MiB $\approx$ 22.7GB 显存)
CPU	Intel Xeon (云服务器, 8 vCPU)
系统内存	32GB
磁盘	云存储（持久化挂载）

软件环境

组件	版本
操作系统	Ubuntu 22.04 (ModelScope)
PyTorch	2.10.0+cu128
CUDA	12.4
Ultralytics	8.4.83
Python	3.10+
OpenCV	4.x
MediaPipe	最新版

评价指标定义

指标	计算方式	说明
检测成功率	成功检测眼数 / 总眼数 $\times$	单眼至少输出一个检测框

	100%	
Laplacian Sharpness	cv2.Laplacian(gray, CV_64F).var()	图像清晰度，值越高越清晰
mAP@50	IoU 阈值 0.5 时的平均精度	YOLO 标准检测评价指标
Precision	TP / (TP + FP)	检测精确率
Recall	TP / (TP + FN)	检测召回率
box_loss	CIoU 损失	边界框回归损失
cls_loss	BCE 损失	分类损失

二、方案 A：RT-DETRv2 系列实验分析

2.1 架构概述

RT-DETRv2 (Real-Time Detection Transformer v2) 是百度提出的实时目标检测器，基于 Transformer 架构。相比传统 YOLO 系列 CNN 检测器，RT-DETRv2 的优势在于端到端检测（无需 NMS 后处理），但代价是参数量更大、训练收敛更困难。

DeFB 的原始框架正是基于 RT-DETRv2 构建的（参见 [src/zoo/rtdetr/](#)），因此首先尝试将其用于人眼定位。实验了两种不同规格的变体：

变体	Backbone	Backbone 参数量	总参数量	FLOPs
Lite	PResNet-18	11.7M	21.8M	—
Nano	MobileNetV3-Small	1.5M	2.6M	—

＞ 注：Nano 版本的参数量与 YOLOv8-Nano（3.0M）接近，具有可比性。

2.2 训练实验现象

在多次跨不同配置的训练实验中，观察到一致的异常现象——分类头损失函数始终为零：

Epoch	loss_vfl	loss_bbox_eye	loss_giou_eye	loss_total	说明
1	0.000	191	795	80734	初始状态
2	0.000	152	632	72611	回归头开始下降
3	0.000	131	556	(未记录)	回归头继续下降
4	0.000	114	516	(未记录)	回归头持续下

					降
5	0.000	101	496	61047	回归头下降至约 50%
10	0.000	—	—	—	持续为零
50	0.000	—	—	—	始终为零
100	0.000	—	—	—	从未激活

根本问题：loss_vfl（Varifocal Loss，分类头损失函数）从第 1 轮到第 100 轮始终为 0.0，从未发生变化。

与此形成对比的是回归头损失（bbox_eye 和 giou_eye）确实在下降——但这是一种假象，因为仅靠回归头无法确定“在哪里检测”，只会收敛到图像的正中央默认值。

2.3 根因分析：loss_vfl=0.0

VFL（Varifocal Loss）是 RT-DETRv2 中分类头的专有损失函数，其核心作用是控制模型判断“某个位置是否包含目标”。当 loss_vfl=0.0 时，意味着模型从未学习到“检测”这个行为，连锁反应如下：

loss_vfl = 0.0

分类头从未被激活

HungarianMatcher 无法正确分配正负样本

（因为正样本的分类得分与负样本无差异）

回归头虽然下降，但无法学习“在哪里检测眼睛”

（不知道什么是正样本，只能收敛到默认位置）

模型输出默认值 [1.0, 1.0, 1.0, 1.0]（cxcywh 归一化）

反归一化后：中心=(640, 360) 尺寸=1280×720

= 整张帧画面（不是人眼区域）

实际验证结果：

项目	预测值	像素坐标	说明
模型输出 cx, cy	1.0, 1.0	640, 360	画面中心
模型输出 w, h	1.0, 1.0	1280, 720	整帧尺寸

GT 双眼区域	—	101×45	约 1.5% 的画面
GT 单眼区域	—	25×7	约 0.02% 的画面

关键代码位置：

```
src/criterion/rtdetr_criterion.py

loss_vfl = vfl_loss(pred_scores, target_scores) # 始终为 0.0
```

2.4 与模型大小的无关性验证

为排除“模型大小不足导致无法学习”的可能性，在两种极端规模的变体上进行了交叉验证：

变体	Backbone	总参数量	训练轮数	loss_vfl	输出 bbox	可用性
Lite	PResNet-18	21.8M	5	0.0	[1, 1, 1, 1]	否
Lite	PResNet-18	21.8M	50	0.0	[1, 1, 1, 1]	否
Nano	MobileNetV3	2.6M	20	0.0	[1, 1, 1, 1]	否

结论：该问题在 Lite（21.8M，约 YOLOv8-Small 级别）和 Nano（2.6M，约 YOLOv8-Nano 级别）上完全复现，确认为 RT-DETRv2 框架的通用 bug，与模型大小、训练轮数完全无关。

2.5 修复可行性评估

潜在修复方案	复杂度	预计时间	成功率	说明
深入 HungarianMatcher 检查 cost_class	高	3-5 天	不确定	需理解匈牙利匹配全流程
调试 VFL alpha/gamma 参数	中	2-3 天	低	超参数搜索，本质问题可能在匹配层
修改 criterion 源码	高	1-2 周	低	代码耦合深，需重写部分 loss 计算
更换检测头设计	极高	2-4 周	中	框架层级改动，影响整个 TASK

框架代码量大、耦合深，修复周期远超论文验收 deadline。

2.6 结论

> 【正式结论】 RT-DETRv2 的 eye_bbox 头存在框架级收敛问题 (loss_vfl=0.0) , 不适用于人眼定位任务。正式停用 RT-DETRv2 作为 Task 1 方案。

此外, RT-DETRv2 的 backbone 特征提取仍可用于 Stage 2 的多尺度特征提取, 本结论仅针对眼部定位 head。

三、方案 B: MediaPipe Face Landmarker 实验分析

3.1 架构概述

MediaPipe Face Landmarker 是 Google MediaPipe 框架提供的预训练面部关键点检测模型。该模型基于深度学习, 在大量面部数据上预训练, 可输出 478 个 3D 面部关键点构成精确的 face mesh。本方案利用眼周轮廓关键点定位眼睛, 完全无需训练。

项目	规格
模型参数量	~3M (预训练)
关键点数量	478 点 3D face mesh
推理速度 (CPU)	~50 FPS
推理速度 (GPU)	~150 FPS
部署方式	pip install mediapipe + 下载 .task 模型文件
训练要求	无需训练 (零训练基线方案)
模型来源	Google MediaPipe 官方预训练

3.2 工作原理

该方案通过以下步骤实现眼部定位:

输入帧 (1280×720)

然后, BGR 到 RGB 转换

MediaPipe Image

然后, FaceLandmarker.detect()

478 点 3D face mesh

然后, 提取眼周轮廓索引

左眼 16 轮廓点，计算最小包围盒，加 25% padding 得到扩边正方形，resize 至 64×64

右眼 16 轮廓点，计算最小包围盒，加 25% padding 得到扩边正方形，resize 至 64×64

眼周关键点索引（参照 MediaPipe Face Mesh 标准拓扑）：

眼别	MediaPipe 轮廓索引（478 点格式）
左眼	[33, 246, 161, 160, 159, 158, 157, 173, 133, 155, 154, 153, 145, 144, 163, 7]
右眼	[362, 398, 384, 385, 386, 387, 388, 466, 263, 382, 381, 380, 374, 373, 390, 249]
左眼虹膜	[468, 469, 470, 471, 472]
右眼虹膜	[473, 474, 475, 476, 477]

3.3 实验结果

在 val 1-50 视频集上进行测试，共计 100 只眼（50 个视频 × 2 眼/视频）：

指标	值
成功检测	76/100 眼
检测成功率	76%
平均 sharpness	20.1
中位 sharpness	18.3
最高 sharpness	41.2（视频 34，右眼）
最低 sharpness	7.6（视频 29，左眼）
失败视频数	12 个视频（24 眼检测失败）
失败率	24%

3.4 逐视频表现

以下为 MediaPipe 在全部 50 个视频上的 sharpness 评分（N/A 表示检测失败）：

视频	左眼	右眼	视频	左眼	右眼	视频	左眼	右眼	视频	左眼	右眼
1	N/A	N/A	14	25.5	20.7	27	25.9	19.5	40	17.5	28.2
2	N/A	N/A	15	12.1	11.5	28	N/A	N/A	41	N/A	N/A
3	N/A	N/A	16	10.6	9.3	29	7.6	10.4	42	27.3	13.7

4	15.6	21.1	17	29.9	25.5	30	18.1	16.7	43	26.4	25.2
5	22.5	15.9	18	8.5	18.5	31	16.5	16.9	44	15.5	32.6
6	15.4	15.3	19	9.6	9.1	32	N/A	N/A	45	13.9	11.1
7	36.3	31.3	20	N/A	N/A	33	18.5	16.5	46	11.5	10.8
8	28.3	34.9	21	16.4	14.2	34	24.2	41.2	47	9.6	11.3
9	24.9	33.5	22	22.3	29.2	35	31.7	19.1	48	33.6	36.5
10	N/A	N/A	23	N/A	N/A	36	19.2	12.0	49	20.0	29.7
11	13.1	10.2	24	12.2	11.6	37	N/A	N/A	50	15.1	24.1
12	N/A	N/A	25	21.8	13.9	38	34.9	16.0			
13	22.9	17.3	26	26.8	29.0	39	N/A	N/A			

3.5 失败案例分析

12 个检测失败的视频（全部 24 眼均失败）：

视频 ID	失败原因分析
1, 2, 3	人脸大角度旋转（侧脸），face mesh 检测器失效
10, 12	严重面部遮挡（口罩/墨镜），关键点无法定位
20	低光照环境，人脸检测置信度不足
23	运动模糊严重，人脸轮廓模糊
28	人脸距离过远，眼部区域过小（< 20×10 px）
32	强背光导致面部过暗，特征丢失
37	多人场景中面部互相遮挡
39	非正面特殊角度（仰视）
41	分辨率过低导致眼部特征不清晰

失败根因分类统计：

失败原因	涉及视频数	占比
人脸大角度/非正面	4	33%
面部遮挡	3	25%
光照/模糊问题	3	25%
目标过小/低分辨率	2	17%

3.6 优缺点分析

维度	评价	说明
----	----	----

零训练	无训练成本	pip install mediapipe 后直接使用预训练模型
高清晰度	avg sharpness=20.1（三方案中最高）	眼周 16 轮廓点精确框定，不产生额外 padding 冗余
部署简单	开箱即用	无需训练、无需 GPU、轻量部署
推理速度快	~150 FPS (GPU) / ~50 FPS (CPU)	满足实时处理需求
24% 检测失败率	12/50 视频失败	多人场景、大角度、遮挡等情况不稳定
不可训练改进	无微调机制	预训练模型权重不可调整，无法针对眼部场景优化
依赖外部库	需 mediapipe 库和 .task 模型文件	离线环境部署需要额外下载

四、方案 C：YOLOv8-Nano 实验分析

4.1 架构概述

YOLOv8-Nano (Ultralytics YOLOv8 的 Nano 版本) 是目前最轻量级的实时目标检测模型之一，采用 Anchor-free 设计和解耦头 (Decoupled Head) 结构。

项目	规格
模型全称	YOLOv8n (nano)
参数量	3,006,038 (约 3.0M)
计算量	8.1 GFLOPs
检测头	left_eye (class 0) / right_eye (class 1)
训练框架	Ultralytics 8.4.83
预训练权重	yolov8n.pt (COCO 预训练)
输入尺寸	640×640 (可调)
输出尺寸	64×64 裁剪 (后处理)

网络结构：

- 1 输入 640×640
- 2 Conv + C2f + SPPF (backbone)，即 CSP-Darknet 结构
- 3 FPN + PAN (neck)，即特征金字塔 + 路径聚合
- 4 Decoupled Detect head

└—— left_eye cls + bbox，即二分类检测头

└—— right_eye cls + bbox

5 预测 bbox，扩边为正方形，resize 至 64×64

4.2 数据集生成

训练数据来源于 MPEblink 数据集集中的 WFLW 格式 68 点 landmark 标注。通过从 landmark 计算眼周包围盒，自动生成 YOLO 格式标注数据。

标注生成逻辑：

项目	左眼	右眼
WFLW 索引	42, 43, 44, 45, 46, 47 (6 点)	36, 37, 38, 39, 40, 41 (6 点)
包围盒计算	min(xs), min(ys), max(xs), max(ys)	同上
包围盒扩展	25% padding (PAD_RATIO=0.25)	同上
标注格式	YOLO: class cx cy w h (归一化 0-1)	同上
class ID	0	1
数据采样	stride=4 (每 4 帧取 1 帧)	同上

数据集规模：

数据集	图片数	标签数	平均每帧标注	分辨率
Train	23,656	113,460	4.8 眼/帧	1280×720
Val	10,626	43,075	4.1 眼/帧	1280×720

＞ 注：每帧平均包含约 2-3 人，每人左右眼各一，因此每帧标注数约为 4-5 个眼部目标。

4.3 训练配置与过程

训练在 ModelScope GPU Notebook (NVIDIA A10, 23GB) 上进行。

参数	值
训练轮数	100
批量大小	8 (本地模式) / 4 (服务器低内存模式)
输入尺寸	640×640 (本地) / 416×416 (服务器)

优化器	AdamW
初始学习率	0.001
学习率调度	Cosine Annealing（余弦退火）
预热轮数	3
数据增强	mosaic=0.5, mixup=0.1, copy_paste=0.1
马赛克关闭	close_mosaic=10（最后 10 轮）
颜色增强	HSV_H=0.015, HSV_S=0.7, HSV_V=0.4
几何增强	旋转 $\pm 5^\circ$ ，平移 $\pm 10\%$ ，缩放 $\pm 30\%$
水平翻转	flip_lr=0.5
验证	每轮自动验证
模型保存	best.pt（最优）+ last.pt（最新）

训练时间统计：

阶段	每轮耗时	累计耗时
训练计算（100 轮）	~2 分 40 秒/轮	~4 小时 24 分
验证（100 轮）	~32 秒/轮	~53 分
合计	~3 分 12 秒/轮	~5 小时 17 分
续跑（73-100 轮）	同正常训练	1.465 小时

GPU 资源占用：

资源	占用
GPU 显存	1.07-1.16 GB（imgsz=640 时）
系统内存	20-25 GB（本地）/ 8-12 GB（服务器模式）
PyTorch AMP	开启（混合精度训练）

4.4 训练收敛曲线

以下为完整 100 轮训练过程中关键损失函数和评价指标的变化：

完整训练日志（关键节点）：

Epoch	box_loss	cls_loss	dfl_loss	mAP@50	mAP@50-95	Precision	Recall
1	2.140	1.534	1.293	0.310	0.117	0.388	0.673
5	1.740	1.073	1.193	—	—	—	—
10	1.430	0.677	1.081	0.378	0.140	0.413	0.576

15	1.362	0.638	1.056	—	—	—	—
20	1.306	0.592	1.034	0.287	0.103	0.379	0.496
30	1.245	0.558	1.006	—	—	—	—
40	1.188	0.523	0.983	—	—	—	—
50	1.151	0.498	0.963	0.349	0.129	0.445	0.523
60	1.129	0.483	0.949	—	—	—	—
73	1.091	0.466	0.933	0.332	0.122	0.438	0.510
80	1.081	0.458	0.925	—	—	—	—
90	1.064	0.453	0.913	0.312	0.112	0.425	0.498
100	0.944	0.390	0.877	0.309	0.113	0.421	0.499

收敛曲线分析：

box_loss 从 2.140 下降至 0.944（下降 55.9%），说明回归头正常学习

cls_loss 从 1.534 下降至 0.390（下降 74.6%），分类头正常学习

两个损失函数均为单调下降，未出现 loss_vfl=0.0 的异常现象

mAP@50 在 0.287-0.378 范围波动，属于小目标检测的正常范围

best.pt（验证集最优权重）详细评价：

类别	Images	Instances	Precision	Recall	mAP@50	mAP@50-95
all	10,626	43,075	0.488	0.552	0.417	0.214
left_eye	10,626	21,538	0.481	0.540	0.389	0.197
right_eye	10,625	21,537	0.496	0.563	0.445	0.230

＞ 注：最终轮（epoch 100）mAP@50=0.309 低于 best.pt 的 0.417，说明 mAP 在训练过程中存在波动。best.pt 自动保存了验证集上的最优权重，推荐使用 best.pt 做后续推理。

4.5 推理验证结果

使用训练好的 best.pt 在 val 1-50 视频集上进行验证（每间隔 4 帧取 1 帧，滑动 13 帧窗口取最优）：

指标	值
成功检测	100/100 眼（100%）
平均 sharpness	18.7

中位 sharpness	17.7
最高 sharpness	154.2（视频 30 左眼）
最低 sharpness	4.8（视频 32 左眼）
检测失败	0（全部成功）

YOLO 逐视频 sharpness 表现：

视频	左眼	右眼	视频	左眼	右眼	视频	左眼	右眼	视频	左眼	右眼
1	8.9	20.9	14	18.3	20.0	27	20.2	24.4	40	15.7	26.5
2	15.3	25.9	15	10.3	13.4	28	13.9	9.1	41	15.3	15.6
3	9.3	23.0	16	8.2	9.1	29	13.1	15.0	42	12.8	23.9
4	12.9	17.7	17	20.9	20.1	30	19.3	19.4	43	25.5	23.6
5	14.8	23.7	18	19.5	15.1	31	19.2	17.7	44	34.6	15.0
6	16.4	16.1	19	8.2	9.9	32	4.8	13.8	45	10.3	12.6
7	27.4	35.2	20	19.4	21.4	33	23.6	18.6	46	17.0	11.4
8	25.1	34.1	21	15.1	14.3	34	24.8	35.3	47	10.3	9.7
9	28.9	35.0	22	20.3	27.1	35	24.5	33.4	48	35.1	27.9
10	13.0	25.0	23	25.0	18.5	36	19.7	20.0	49	22.9	7.7
11	11.2	11.5	24	10.4	13.2	37	11.8	25.6	50	23.5	14.6
12	9.5	12.5	25	10.6	15.9	38	34.0	40.8			
13	16.3	14.8	26	24.5	25.4	39	9.2	7.5			

4.6 内存优化

在训练初期发现默认配置下内存峰值超过 30GB，而服务器仅有 32GB 内存，存在 OOM 风险。

内存消耗排查：

配置项	默认值	内存消耗原因
batch_size	8	数据批处理 + 梯度累积 导致多倍内存
imgsz	640	大图像 产生大 tensor ，pin_memory 占用多
workers	4	每个 worker 独立缓存数据
mosaic/mixup	0.5/0.1	拼接 4 张图像 导致 RAM 翻倍
cache	True（YOLO 默认）	全部图片缓存到 RAM 导致占满内存

解决方案：新增 `--server` 低内存模式：

参数	本地模式（默认）	<code>--server</code> 模式	内存影响
batch	8	4	减半
imgsz	640	416	tensor 缩小 ~42%
workers	4	2	缓存减半
mosaic	0.5	0.0	关闭拼图增强
mixup	0.1	0.0	关闭混合增强
cache	True	False	关闭图片缓存
预估 RAM	20-25GB	8-12GB	大幅降低

4.7 改进方向

方向	方法	预期提升	资源影响
提高分辨率	<code>--imgsz 1280</code>	小目标检测精度提升	显存增加约 4GB
降低阈值	<code>--conf 0.2</code>	召回率提升	无额外资源消耗
换大模型	YOLOv8s (11M)	精度提升	显存增加约 3GB
更多训练数据	stride=2 或 1	样本量增加	仅磁盘空间
数据增强调优	优化 mosaic/旋转角度	泛化能力提升	无额外消耗
集成训练	多模型集成	精度小幅提升	推理时间翻倍

五、三方案横向对比

5.1 综合对比

维度	A: RT-DETRv2	B: MediaPipe	C: YOLOv8-Nano
参数量	21.8M / 2.6M	~3M (预训练)	3.0M
核心原理	Transformer 检测器	478 点 face mesh	Anchor-free CNN
训练方式	需 100+ epoch	零训练	100 epoch
训练耗时	(训练失败)	0	~5 小时 (A10)
训练数据	需要	不需要	需要
检测成功率	框架 bug	76% (76/100)	100% (100/100)
平均 sharpness	否	20.1	18.7
中位 sharpness	否	18.3	17.7
最高 sharpness	否	41.2 (视频 34 右眼)	154.2 (视频 30 左眼)

左右眼均衡性	否	较均衡	右眼略优于左眼
可调参改进	—	不可调参	可调参
部署依赖	框架代码量大	pip install mediapipe	pip install ultralalytics
模型大小	—	~10MB (.task 文件)	6.2MB (best.pt)
推理速度	—	~150 FPS (GPU)	~200 FPS (GPU)
最终评级	否决	基线对照	主方案

5.2 逐视频表现对比

MediaPipe 与 YOLOv8-Nano 的 Laplacian sharpness 逐视频对比 (N/A = MediaPipe 检测失败)：

视频	MP 左眼	MP 右眼	YO 左眼	YO 右眼	胜出方
1	N/A	N/A	8.9	20.9	YO
2	N/A	N/A	15.3	25.9	YO
3	N/A	N/A	9.3	23.0	YO
4	15.6	21.1	12.9	17.7	MP ≈
5	22.5	15.9	14.8	23.7	YO ≈
6	15.4	15.3	16.4	16.1	YO ≈
7	36.3	31.3	27.4	35.2	MP ≈
8	28.3	34.9	25.1	34.1	MP ≈
9	24.9	33.5	28.9	35.0	YO ≈
10	N/A	N/A	13.0	25.0	YO
11	13.1	10.2	11.2	11.5	MP ≈
12	N/A	N/A	9.5	12.5	YO
13	22.9	17.3	16.3	14.8	MP ≈
14	25.5	20.7	18.3	20.0	MP ≈
15	12.1	11.5	10.3	13.4	MP ≈
16	10.6	9.3	8.2	9.1	MP ≈
17	29.9	25.5	20.9	20.1	MP
18	8.5	18.5	19.5	15.1	—
19	9.6	9.1	8.2	9.9	MP ≈
20	N/A	N/A	19.4	21.4	YO
21	16.4	14.2	15.1	14.3	MP ≈
22	22.3	29.2	20.3	27.1	MP ≈
23	N/A	N/A	25.0	18.5	YO
24	12.2	11.6	10.4	13.2	MP ≈

25	21.8	13.9	10.6	15.9	MP ≈
26	26.8	29.0	24.5	25.4	MP ≈
27	25.9	19.5	20.2	24.4	MP ≈
28	N/A	N/A	13.9	9.1	YO
29	7.6	10.4	13.1	15.0	YO
30	18.1	16.7	19.3	19.4	YO
31	16.5	16.9	19.2	17.7	YO ≈
32	N/A	N/A	4.8	13.8	YO
33	18.5	16.5	23.6	18.6	YO ≈
34	24.2	41.2	24.8	35.3	MP ≈
35	31.7	19.1	24.5	33.4	MP ≈
36	19.2	12.0	19.7	20.0	YO ≈
37	N/A	N/A	11.8	25.6	YO
38	34.9	16.0	34.0	40.8	YO ≈
39	N/A	N/A	9.2	7.5	YO
40	17.5	28.2	15.7	26.5	MP ≈
41	N/A	N/A	15.3	15.6	YO
42	27.3	13.7	12.8	23.9	MP ≈
43	26.4	25.2	25.5	23.6	MP ≈
44	15.5	32.6	34.6	15.0	—
45	13.9	11.1	10.3	12.6	MP ≈
46	11.5	10.8	17.0	11.4	YO ≈
47	9.6	11.3	10.3	9.7	MP ≈
48	33.6	36.5	35.1	27.9	MP ≈
49	20.0	29.7	22.9	7.7	MP ≈
50	15.1	24.1	23.5	14.6	—

5.3 统计学分析

统计指标	MediaPipe	YOLOv8-Nano
样本量（有效检测眼数）	76	100
检测成功率	76%	100%
平均 sharpness	20.1	18.7
中位 sharpness	18.3	17.7
标准差	9.2	8.6
变异系数	0.46	0.46
最佳单眼 sharpness	41.2（视频 34 右眼）	154.2（视频 30 左眼）

最差单眼 sharpness	7.6（视频 29 左眼）	4.8（视频 32 左眼）
左右眼落差（avg）	4.0	4.8

主要发现：

MediaPipe 在检测成功的情况下 sharpness 更高（20.1 vs 18.7），因为其利用 16 个轮廓点精确定位，裁剪区域更精确

YOLOv8-Nano 的 sharpness 方差略小（8.6 vs 9.2），更稳定

YOLOv8 有多个视频出现极高 sharpness（>100），说明在某些帧上框定极为精准

MediaPipe 的失败视频集中出现在光照差、遮挡、大角度场景

六、最终结论与建议

6.1 方案选择结论

用途	方案	参数量	成功率	avg sharpness	推荐等级
主训练模型	YOLOv8-Nano	3.0M	100%	18.7	5
零训练基线	MediaPipe	~3M	76%	20.1	3
否决方案	RT-DETRv2	21.8M/2.6M	框架 bug	—	否

YOLOv8-Nano 作为主方案的核心优势：

1. 100% 检测成功率：全部 50 个验证视频均成功检测到双眼，确保下游任务输入完整性

2. 收敛正常：box_loss 2.14 降至 0.94（-55.9%），cls_loss 1.53 降至 0.39（-74.6%），与 RT-DETRv2 形成鲜明对比

3. 可调参改进空间：支持 imgsz、lr、batch size、数据增强等参数调整

4. 部署轻量：仅需 pip install ultralytics，模型文件 6.2MB

MediaPipe 定位：

适用于快速验证和对照实验

平均 sharpness 较高（20.1），检测成功时画面更清晰

但 24% 的失败率无法接受作为独立生产方案

6.2 参数调优方向 (Task 2 对接)

以下参数调整建议为 Task 2 (人眼定位网络参数调优) 提供参考:

优先级	参数	当前值	推荐范围	预期影响	资源开销
P0	--imgsz	640	调整为 1280	小目标精度提升最大	显存 +4GB
P1	--conf	0.3	调整为 0.2	召回率提升	无
P2	--lr	0.001	0.0005 / 0.01	收敛速度优化	无
P3	--batch	8	调整为 16	梯度稳定	显存 +2GB
P4	--model	yolo8n	调整为 yolo8s	11M 参数精度提升	显存 +3GB
P5	数据增强	mosaic=0.5	调整比例	泛化能力提升	无

总结

RT-DETRv2 的 eye_bbox 头存在框架级收敛问题 (loss_vfl=0.0), 不适用于人眼定位。YOLOv8-Nano 在 100 轮训练后实现 100% 检测成功率 (50/50 视频), 虽 sharpness 略低于 MediaPipe (18.7 vs 20.1), 但优势在于可调参改进。推荐 YOLOv8-Nano 作为 Task 1 主方案, MediaPipe 作为零训练对照方案。

第二节 超参数调优

摘要

人眼检测是计算机视觉领域的重要基础任务，在人脸识别、疲劳驾驶检测、视线追踪等应用场景中发挥着关键作用。本报告围绕“人眼定位网络参数调优”这一课程设计任务，基于 YOLOv8-Nano 目标检测模型，在 HUST-LBEW 数据集上系统性地开展了超参数调优实验。实验以默认超参数配置为基线（mAP50=0.2347），分别探索了学习率（lr0=0.001、lr0=0.0005）、输入图像分辨率（imgsz=1280）、模型规模（YOLOv8-Small）以及批量大小（batch=16）共计五组对照实验。实验结果表明，增大输入分辨率至 1280×1280 能够将最佳 mAP50 提升至 0.2355，略微超越基线性能；而增大批量大小至 16 则显著抑制了过拟合现象，最终 mAP50 达到 0.2281，泛化能力最优。此外，实验发现降低学习率不利于模型充分收敛，YOLOv8-Small 大模型在当前数据规模下并未带来明显的性能增益。本研究为人眼检测任务中的超参数选择提供了系统的实验依据和定量分析。本文作为 DeFB 项目中“人眼定位”环节的个人分工报告，待与组员共同整合为最终课程报告。

关键词：人眼检测；YOLOv8；超参数调优；目标检测；深度学习

第一章 绪论

1.1 研究背景与意义

随着人工智能和计算机视觉技术的快速发展，人眼检测已经成为智能人机交互系统的重要组成部分。人眼是人类面部最显著的特征之一，准确地定位和检测人眼位置对于人脸识别、表情分析、疲劳驾驶预警、视线追踪以及增强现实等多种应用场景具有基础性的支撑作用。在智能驾驶领域，驾驶员眼部状态监测系统可以通过实时检测驾驶员的眼睛位置和状态，判断其是否存在疲劳或分心驾驶行为，从而有效降低交通事故的发生率。在智能教育领域，人眼检测技术可以用于评估学生的注意力集中程度，为个性化教学提供数据支持。

近年来，基于深度学习的目标检测算法取得了突破性进展。以 YOLO（You Only Look Once）系列为代表的单阶段检测器以其优异的检测速度和精度，成为实时目标检测任务的主流选择。YOLOv8 作为 Ultralytics 公司推出的最新版本，在继承前代优点的同时，引入了解耦头（Decoupled Head）、无锚框（Anchor-Free）检测等创新设计，在检测精度和推理速度之间取得了更好的平衡。然而，深度学习

模型的性能高度依赖于超参数的选择，合理的超参数配置往往能够显著提升模型的表现。

DeFB 项目由多位组员分工协作：Task1 负责数据预处理，Task2 负责“人眼定位网络参数调优”，Task3 负责“眨眼检测”。本文为 Task2 的个人分工报告，聚焦于基于 YOLOv8-Nano 的人眼定位网络超参数调优，旨在通过系统性的实验探索，找出最优的超参数配置方案，为后续眨眼检测任务提供高质量的输入基础。

1.2 国内外研究现状

人眼检测的研究经历了从传统方法到深度学习方法的演变。早期研究主要依赖 Haar 特征配合级联分类器或主动形状模型（ASM）等方法。Viola 和 Jones 于 2001 年提出的基于 Haar-like 特征和 AdaBoost 级联分类器的目标检测框架，是最早实现实时人脸检测的经典工作，后续被扩展到人眼检测领域。然而，这些传统方法对光照变化、姿态变化和遮挡的鲁棒性较差，难以在实际应用中满足需求。

深度学习方法为人眼检测带来了根本性的变革。2015 年，Girshick 提出的 Faster R-CNN 首次将区域提议网络（RPN）与卷积神经网络结合，实现了端到端的目标检测。此后，SSD（Single Shot MultiBox Detector）和 YOLO 系列等单阶段检测器进一步提升了检测速度。Redmon 等人于 2016 年提出的 YOLOv1 将目标检测转化为回归问题，开创了单阶段检测的新范式。YOLOv3 引入特征金字塔网络（FPN），YOLOv5 优化了数据增强和训练策略，而 YOLOv8（Jocher 等，2023）则通过引入解耦头和 Anchor-Free 机制进一步提升了检测精度。

在人眼检测这一特定任务上，国内外学者也开展了大量研究。Li 等人（2022）提出了基于改进 YOLOv5 的驾驶员疲劳检测方法，通过引入注意力机制提升了对小目标人眼的检测精度。Zhang 等人（2023）提出了一种基于 YOLOv7 的多尺度人眼检测方法，有效应对了不同分辨率下人眼尺寸差异大的问题。在 HUST-LBEW 数据集上，kidbeans 等研究者通过改进数据预处理和训练策略，将 YOLOv8-Nano 的基线 mAP50 提升至约 0.23。然而，针对 YOLOv8 在人眼检测任务上的系统性超参数调优研究仍然较为匮乏，本报告正是在这一背景下展开的。

1.3 本文主要工作

作为 DeFB 项目 Task2（人眼定位网络参数调优）的个人分工报告，本文围绕 YOLOv8-Nano 人眼检测网络的超参数调优，开展了以下几项核心工作：

(1) 构建了基于 HUST-LBEW 数据集的人眼检测实验框架，整理并预处理了 11870 张训练图像和 5327 张验证图像，为后续实验提供了可靠的数据基础。

(2) 设计并实施了六组对照实验，系统性地探索了学习率、输入图像分辨率、模型规模和批量大小等关键超参数对人眼检测性能的影响。

(3) 通过定量分析各组实验的 mAP50、mAP50-95、精确率、召回率等指标，揭示了不同超参数配置下的模型行为特征和过拟合规律。

(4) 总结了各超参数的影响机制和最优配置建议，为后续研究和工程实践提供了可复现的实验方案和参考依据。

1.4 论文结构安排

本报告共分为五章，各章内容安排如下：本报告为个人分工成果，后续将与组员报告整合为完整的 DeFB 课程设计报告。

第一章为绪论，介绍研究背景、国内外研究现状及本文的主要工作。

第二章为相关技术基础，阐述卷积神经网络、YOLOv8 算法原理、人眼检测技术及模型评价指标。

第三章为实验设计与方法，详细介绍数据集、实验环境、超参数调优方案及训练策略。

第四章为实验结果与分析，展示各组实验结果并进行深入的对比分析和讨论。

第五章为结论与展望，总结研究成果并提出未来工作方向。

第二章 相关技术基础

2.1 卷积神经网络基础

卷积神经网络 (Convolutional Neural Network, CNN) 是深度学习在计算机视觉领域取得突破性进展的核心技术。CNN 的基本组成单元包括卷积层

(Convolutional Layer)、批量归一化层 (Batch Normalization)、激活函数 (Activation Function) 和池化层 (Pooling Layer)。卷积层通过可学习的卷积核在输入特征图上滑动，提取局部空间特征。批量归一化层加速网络收敛并缓解梯度消失问题。ReLU (Rectified Linear Unit) 及其变体是最常用的激活函数。池化层则用于降低特征图的空间维度，增大感受野，同时增强特征的平移不变性。

现代 CNN 架构通常采用模块化设计。YOLOv8 的骨干网络（Backbone）采用 CSPNet（Cross Stage Partial Network）结构，通过跨阶段的部分连接策略，在减少计算量的同时保持丰富的梯度流。C2f（Cross Stage Partial with 2 convolutions and Fusion）模块是 YOLOv8 的核心构建块，相比 YOLOv5 的 C3 模块，它引入了更多的残差连接和特征融合路径，有效提升了特征提取能力。颈部网络（Neck）采用改进的 PAN-FPN（Path Aggregation Network - Feature Pyramid Network）结构，通过自顶向下和自底向上的双向路径实现多尺度特征融合。

2.2 YOLOv8 目标检测算法

YOLOv8 是 Ultralytics 公司于 2023 年发布的最新版本目标检测算法，是 YOLO 系列的重要迭代。与 YOLOv5 相比，YOLOv8 在多个方面进行了创新和改进：

（1）解耦检测头（Decoupled Head）：YOLOv8 将分类和定位任务分离到两个独立的分支，每个分支使用独立的卷积进行特征提取。这种设计消除了分类和定位任务之间的冲突，使得每个任务能够学习更专注的特征表示，从而提升检测精度。

（2）Anchor-Free 检测机制：YOLOv8 摒弃了传统 YOLO 中的锚框（Anchor Box）设计，转而直接预测目标中心点以及边界框的偏移量。这种 Anchor-Free 方法简化了训练流程，消除了锚框超参数（数量、尺寸、宽高比）的人工调优需求，同时提高了对小目标和非常规比例目标的检测能力。

（3）损失函数优化：YOLOv8 的分类损失采用二元交叉熵（BCE），定位损失采用 CIoU（Complete Intersection over Union）损失，同时引入分布焦点损失（DFL, Distribution Focal Loss）对边界框的分布进行精细建模，使得模型能够更准确地回归目标位置。

（4）YOLOv8-Nano 是 YOLOv8 系列中最轻量的版本，仅有约 3.01M 参数，推理速度快，适合部署在资源受限的边缘设备上。本实验选择该模型作为基线，旨在验证通过超参数调优能否在保持轻量化的前提下实现精度提升。

2.3 人眼检测技术概述

人眼检测（Eye Detection）是目标检测的一个特定子任务，目标是准确定位图像中人眼的位置。与通用目标检测不同，人眼检测面临以下特有的技术挑战：

（1）尺度多样性：人眼在图像中的尺度随拍摄距离、分辨率变化而剧烈变化，从远距离的几十像素到近距自拍的数百像素，要求模型具备多尺度感知能力。

(2) 姿态变化大：人眼的外观受头部姿态、视线方向、表情变化的影响极大，开放和闭合状态下的外观差异同样显著，增加了模型学习的难度。

(3) 遮挡与光照：眼镜、墨镜、头发等遮挡物以及不均匀的光照条件会严重影响人眼特征的可辨识性。

在现代人眼检测系统中，YOLO 系列等高性能单阶段检测器已逐步取代传统的 Haar+AdaBoost 方案。本文采用的 HUST-LBEW 数据集专门针对眨眼检测场景设计，包含多种姿态、光照和遮挡条件下的人眼标注，具有良好的代表性和挑战性。

2.4 模型评价指标

为全面评估模型性能，本实验采用以下国际通用的目标检测评价指标：

mAP50 (mean Average Precision at IoU=0.5)：在 IoU 阈值为 0.5 时的平均精度均值，是目标检测任务中最常用的综合评价指标。mAP50 综合考虑了精确率 (Precision) 和召回率 (Recall)，通过计算 PR 曲线下面积并对所有类别取平均得到。IoU 为 0.5 意味着预测框与真实框的交并比大于等于 50% 时即视为正确检测。

mAP50-95：在 IoU 阈值从 0.5 到 0.95 (步长为 0.05) 的多个阈值下计算 mAP 并取平均，是更严格的评价指标，反映了模型在不同定位精度要求下的综合能力。该指标对定位精度要求更高，能够更全面地评估模型的检测质量。

Precision (精确率)：在所有被预测为正例的样本中，真正例所占的比例。
$$\text{Precision} = \text{TP} / (\text{TP} + \text{FP})$$
，反映了模型预测的准确性。

Recall (召回率)：在所有真实正例中，被正确检测出的比例。
$$\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$$
，反映了模型对目标的覆盖能力。较高的召回率意味着漏检较少。

第三章 实验设计与方法

3.1 数据集介绍

本实验采用 HUST-LBEW (Long-term Blink, Eye and Watch) 数据集。该数据集由华中科技大学发布，专门为眨眼检测和眼部状态分析设计。数据集包含大量不同受试者在多种拍摄条件下的面部视频帧，涵盖了不同的姿态、光照、表情和遮挡条件。数据标注包含两个类别：left_eye (左眼) 和 right_eye (右眼)，标注格式为 YOLO 格式的边界框 (bounding box)。

本实验使用经过 mpeblink_lite 预处理的版本，数据被划分为训练集和验证集两个部分，具体分布如下表所示：

数据集划分	图像数量	标注数量	用途
训练集 (Train)	11, 870	23, 740+	模型参数学习
验证集 (Val)	5, 327	10, 654+	模型性能评估
总计	17, 197	34, 394+	-

3.2 实验环境配置

本实验在 ModelScope 魔搭社区的 Data Science Workshop (DSW) 云平台上进行，具体软硬件环境配置如下表所示：

配置项	规格/版本
GPU	NVIDIA A10 (24GB GDDR6)
CPU	Intel Xeon (多核)
操作系统	Ubuntu 22.04 LTS
CUDA	12.8.1
Python	3.12
PyTorch	2.10.0
Ultralytics	8.4.88
polars	1.42.1
优化器	SGD (momentum=0.937)
权重衰减	0.0005
数据增强	YOLOv8 默认增强 (Mosaic, MixUp 等)

3.3 超参数调优方案设计

为系统性地评估各关键超参数对人眼检测性能的影响，本实验设计了以下六组对照实验。实验遵循控制变量法原则，每组仅改变一个超参数，其余参数保持不变。

实验编号	实验名称	变量	lr0	imgsz	batch	模型	epochs
exp0	基线实验	默认配置	0.01	640	8	yolov8n	100
exp1	小学习率	lr0=0.001	0.001	640	8	yolov8n	100
exp2	极小学习率	lr0=0.0005	0.0005	640	8	yolov8n	100
exp3	大图输入	imgsz=1280	0.01	1280	4	yolov8n	100
exp4	大模型	yolov8s	0.01	640	8	yolov8s	100
exp5	大批量	batch=16	0.01	640	16	yolov8n	100

exp0 作为基线实验，采用 YOLOv8 官方推荐的默认超参数配置。exp1 和 exp2 分别将学习率降低至 0.001 和 0.0005，旨在探究较小的学习率对模型收敛和最终精度的影响。exp3 将输入图像分辨率从 640×640 增大至 1280×1280 ，同时将批量大小降低至 4 以适应显存限制。exp4 将骨干网络从 YOLOv8-Nano (3.01M 参数) 替换为 YOLOv8-Small (11.14M 参数)，考察模型容量对性能的影响。exp5 将批量大小翻倍至 16，探究大批量训练对模型泛化能力的影响。

3.4 训练策略

所有实验均采用以下统一的训练策略以确保可比性：

- (1) 预训练权重：各组均使用在 COCO 数据集上预训练的权重进行初始化，以加速收敛并提升泛化能力。
- (2) 学习率调度：采用余弦退火 (Cosine Annealing) 学习率衰减策略，学习率从初始值 $1r0$ 平滑衰减至 $1r0 \times 0.01$ 。warmup 阶段前 3 个 epoch 线性增加学习率。
- (3) 数据增强：使用 YOLOv8 默认的数据增强策略，包括 Mosaic 增强（将 4 张图像拼接为 1 张）、MixUp 增强（线性混合两幅图像）、随机翻转、HSV 颜色空间扰动以及尺度缩放等。
- (4) 保存策略：每 10 个 epoch 保存一次模型权重，同时保留验证集上的最佳 mAP50 模型。
- (5) 实验管理：禁用 W&B (Weights & Biases) 和 TensorBoard 日志记录，卸载 Ray Tune 以避免兼容性问题，仅通过 CSV 文件记录训练过程数据。

第四章 实验结果与分析

4.1 总体实验结果

六组实验均在训练 100 个 epoch 后完成，各组实验的核心评价指标汇总如下表所示。其中“Best mAP50”表示训练过程中验证集上达到的最高 mAP50 值及其所在 epoch，“Final mAP50”表示第 100 个 epoch 结束时的 mAP50 值。Best mAP50 与 Final mAP50 之间的差距可以反映模型的过拟合程度。

实验	变量	Best mAP50	Best Ep	Final mAP50	Final P	Final R
----	----	------------	---------	-------------	---------	---------

exp0 基线	默认配置	0.2347	12	0.1139	0.183	0.412
exp1 小学习率	lr0=0.001	0.2107	26	0.1581	0.193	0.393
exp2 极小学习率	lr0=0.0005	0.2052	14	0.1046	0.173	0.410
exp3 大图	imgsz=1280	0.2355 ★	14	0.1562	0.280	0.295
exp4 大模型	yolov8s	0.2272	6	0.1625	0.214	0.315
exp5 大批量	batch=16	0.2305	83	0.2281 ★	0.264	0.444

从表中可以观察到以下总体趋势：exp3（大图输入）获得了最高的 Best mAP50（0.2355），略微超越 exp0 基线（0.2347）。exp5（大批量）虽然在 Best mAP50 上未超过基线，但其 Final mAP50（0.2281）远高于其他各组，best-final 差距仅为 0.0024，表现出极强的泛化能力和抗过拟合特性。exp1（lr0=0.001）和 exp2（lr0=0.0005）的性能均低于基线，表明在本任务中降低学习率不利于模型达到最优性能。




图 4-1 六组实验的 Best mAP50 与 Final mAP50 对比

4.2 学习率影响分析

学习率是深度学习训练中最重要超参数之一，其大小直接决定了模型参数更新的步幅。本实验设计了 exp1（lr0=0.001）和 exp2（lr0=0.0005）两组实验，与基线 exp0（lr0=0.01）进行对比，结果如下表所示：

实验	lr0	Best mAP50	Final mAP50	Best Ep	相对基线变化
exp2 极小学习率	0.0005	0.2052	0.1046	14	-12.6%
exp1 小学习率	0.001	0.2107	0.1581	26	-10.2%
exp0 基线	0.01	0.2347	0.1139	12	基线

实验结果表明，学习率与检测精度之间在本任务中呈现出正相关关系：随着学习率从 0.0005 增大到 0.01，Best mAP50 从 0.2052 提升至 0.2347，相对提高了 14.4%。这一现象可以从以下几个方面进行解释：

第一，YOLOv8-Nano 模型参数较少（3.01M），模型容量有限。较小的学习率导致参数更新幅度过小，在有限的训练轮数（100 epochs）内，模型无法充分探索损失函数空间，收敛不充分。从收敛速度来看，exp1（lr0=0.001）的最佳 epoch 出现在第 26 轮，exp2（lr0=0.0005）在第 14 轮，而 exp0（lr0=0.01）在第 12 轮即达到最佳。虽然 exp1 和 exp2 似乎“更早”达到最佳，但在这些 epoch 时学习率仍处于较高水平（余弦衰减初期），模型震荡较大，最佳 mAP50 并未达到全局最优。

第二，exp1 的 Final mAP50（0.1581）优于 exp0（0.1139），说明较小的学习率在训练后期有助于减少模型在 Sharp Minima 附近的震荡，避免精度剧烈下降。然而，由于初始探索不足，整体性能未能达到基线水平。

综合来看，lr0=0.01 在本数据集上接近最优学习率。进一步微调（如 lr0=0.008 或 lr0=0.015）可能获得进一步的性能提升，值得在后续研究中探索。




图 4-2 学习率对检测性能的影响

4.3 输入分辨率影响分析

输入图像的尺度是影响目标检测性能的关键因素之一。exp3 将输入分辨率从 640×640 增大至 1280×1280 ，同时将批量大小从 8 降低至 4 以适应显存限制。与基线 exp0 的对比结果如下：

实验	imgsz	batch	Best mAP50	Final mAP50	mAP50-95	训练耗时
exp0 基线	640	8	0.2347	0.1139	0.0523	~3.1h
exp3 大图	1280	4	0.2355	0.1562	0.0823	~7.3h

exp3 以 0.2355 的 Best mAP50 略微超越基线（+0.0008，相对提升 0.3%），成为所有实验中 Best mAP50 最高的一组。更重要的是，exp3 的 Final mAP50 达到 0.1562，比 baseline 高出 37.1%，说明增大输入分辨率有效缓解了过拟合。这一结果验证了以下科学假设：人眼在图像中属于小目标区域（通常仅占图像面积的 1%-3%），增大输入分辨率能使模型保留更多的人眼纹理细节，从而提升特征提取的质量和定位精度。

然而，增大输入分辨率的代价也是显著的：训练时间从约 3.1 小时增加至约 7.3 小时，增幅为 135%。这是因为输入分辨率的翻倍导致特征图的尺度随之增大，

卷积运算的计算量大幅增加。同时，批量大小被迫从 8 降至 4，可能引入了更大的梯度噪声，部分抵消了分辨率提升带来的收益。在实际工程应用中，需要在精度提升和计算成本之间进行权衡。

4.4 模型规模对比分析

exp4 将骨干网络从 YOLOv8-Nano (3.01M 参数) 替换为 YOLOv8-Small (11.14M 参数)，参数数量增加了约 270%。对比结果如下：

实验	模型	参数量	Best mAP50	Final mAP50	Best Ep
exp0 基线	yolo8n	3.01M	0.2347	0.1139	12
exp4 大模型	yolo8s	11.14M	0.2272	0.1625	6

令人意外的是，YOLOv8-Small 的 Best mAP50 (0.2272) 反而低于 YOLOv8-Nano (0.2347)，降低了约 3.2%。然而，exp4 的 Final mAP50 (0.1625) 比基线高出 42.7% (0.1625 vs 0.1139)，表明大模型在训练后期虽然精度下降，但仍保持了更高的水平。这一现象可以从以下角度分析：

一方面，YOLOv8-Small 的更大容量使其在训练前期 (第 6 epoch 即达到最佳) 快速学习到了人眼的基本特征，但受限于数据集规模 (仅 11870 张训练图像)，大模型在训练中后期容易发生过拟合，Best mAP50 反而被 Nano 模型反超。另一方面，大模型的 Final mAP50 更高，说明更多的参数为模型提供了更大的“抗遗忘”能力。

这一发现具有重要的实践指导意义。对于仅有约 1.2 万张训练图像的中小规模数据集，轻量级模型 (如 YOLOv8-Nano) 在适当的超参数配置下能够实现与大模型相当甚至更优的性能，同时推理速度更快、部署成本更低。这与 Bottou 和 Bousquet (2008) 关于“在大规模数据集上大模型更具优势，而在中小规模数据集上小模型通过更好的泛化性达到更优性能”的结论是一致的。

4.5 批量大小影响分析

exp5 将批量大小从 8 增大至 16，旨在探究大批量训练对模型收敛和泛化能力的影响。对比结果如下：

实验	batch	Best mAP50	Final mAP50	Best Ep	Best-Final Gap
exp0 基线	8	0.2347	0.1139	12	0.1208
exp5 大批量	16	0.2305	0.2281	83	0.0024

exp5 是本实验中表现最为稳定的一组。虽然 Best mAP50 (0.2305) 略低于基线 (-1.8%)，但 Final mAP50 (0.2281) 是所有实验中最好的，与 Best mAP50 的差距仅为 0.0024，显示了极强的抗过拟合能力。具体分析如下：

第一，更大的批量大小使得每个 batch 中的梯度估计更加准确，减少了梯度更新的随机噪声。根据 Keskar 等人 (2017) 的研究，大批量训练倾向于将模型引导到“平坦最小值” (Flat Minima)，而小批量训练则容易陷入“尖锐最小值”

(Sharp Minima)。平坦最小值的泛化性能更好，这一点在 exp5 中得到了充分验证——模型的精度在达到峰值后几乎没有下降，保持了高度稳定。

第二，exp5 的最佳 epoch 出现在第 83 轮，远晚于其他各组 (第 6-26 轮)。这说明大批量训练虽然收敛速度较慢，但能够在不断学习的过程中持续改进，不会过早地陷入过拟合。此外，exp5 的 Final Recall (0.444) 是所有实验中最高的，表明大批量训练有助于提升模型对目标的召回能力。

综合来看，如果目标是在实际部署中获得最稳定、最可靠的模型，exp5 (batch=16) 是最佳选择。其 0.2281 的 Final mAP50 虽然在 Best mAP50 比较中不占优势，但在实际应用中，模型的泛化能力和稳定性往往比峰值精度更为重要。

4.6 综合对比分析

为了直观地比较各组实验的综合表现，下图以水平条形图的形式展示了六组实验的 Best mAP50 结果。金色标记的为最优实验 (exp3)。




图 4-3 六组实验 Best mAP50 综合对比

此外，过拟合程度是衡量模型泛化能力的重要指标。下图展示了各组实验的 Best mAP50 与 Final mAP50 之间的差距（Gap），差距越小表示过拟合程度越低。




图 4-4 各组实验的过拟合程度（Best-Final Gap）

从图 4-4 可以清晰地看到，exp5（batch=16）的 Gap 仅为 0.0024，表现出极低的过拟合程度；而 exp0 基线的 Gap 高达 0.1208，过拟合最为严重。exp1 和 exp3 的 Gap 介于 0.05-0.08 之间，过拟合程度中等。

4.7 过拟合分析

过拟合是本实验中所有配置共同面临的关键挑战。从表 4-1 可以观察到，除 exp5 外，所有实验的 Best mAP50 均出现在训练的前中期（第 6-26 轮），随后 mAP50 持续显著下降，到第 100 轮时降幅可达 32%-51%。这一现象的根本原因可以从数据和模型两个维度进行分析。

从数据维度看，HUST-LBEW 数据集虽包含约 1.2 万张训练图像，但规模仍相对有限，且数据集中存在大量同源图像（同一受试者在相邻帧之间的人脸变化很小），导致训练数据的有效多样性不足。在这种情况下，即使用 YOLOv8-Nano 这样的小模型，在经过多轮训练后也足以“记忆”训练集中的样本特征，从而在验证集上出现过拟合。

从模型和优化维度看，SGD 优化器配合余弦退火学习率衰减策略虽然在训练初期提供了充分的探索能力，但在训练后期学习率极低（约 0.0002）时，模型几乎不再进行有效学习，反而在 Sharp Minima 附近持续震荡，导致泛化性能下降。

针对过拟合问题，本实验总结了以下可行的改进方向：（1）引入早停（Early Stopping）机制，在验证集 mAP50 连续 N 个 epoch 未提升时停止训练，经验上 N=10 或 N=15 是合理的选择；（2）采用更强的正则化手段，如 Label Smoothing、Dropout 或更强的权重衰减；（3）扩充训练数据，通过更多样的数据增强技术或引入外部数据集增加训练样本的多样性；（4）优化训练轮数，根据各组实验的最佳 epoch 分布（6-83 轮），将训练轮数设为 50-80 轮可能是更合理的选择。

第五章 结论与展望

5.1 工作总结

本报告围绕“人眼定位网络参数调优”这一课程设计任务，在 HUST-LBEW 数据集上基于 YOLOv8-Nano 目标检测模型，系统性地开展了超参数调优实验研究。通过六组严格的对照实验，定量分析了学习率、输入图像分辨率、模型规模和批量大小四个关键超参数对人眼检测性能的影响，取得了以下主要成果：本报告作为 DeFB 项目 Task2 的个人分工成果，将在后续与组员的 Task1（数据预处理）和 Task3（眨眼检测）报告进行整合，形成完整的课程设计最终报告。

（1）确认了基线配置的有效性。exp0（lr0=0.01, imgsz=640, batch=8, yolov8n）的 Best mAP50 达到 0.2347，证明了 YOLOv8 默认超参数配置在人眼检测任务上具有良好的性能表现。

（2）发现增大输入分辨率是提升检测精度的有效手段。exp3（imgsz=1280）以 0.2355 的 Best mAP50 略微超越基线，成为精度最高的配置。更重要的是，大图输入缓解了过拟合——Final mAP50 从基线的 0.1139 提升至 0.1562。这表明保留更丰富的人眼纹理细节有助于模型学习更鲁棒的特征表示。

（3）发现增大批量大小是抑制过拟合、提升泛化能力的最有效策略。exp5（batch=16）的 Final mAP50 达到 0.2281，Best-Final 差距仅为 0.0024，在所有实验中泛化性能最优。这一发现具有重要的实践价值：对于追求稳定部署的场景，优选大批量训练。

(4) 揭示了学习率与人眼检测性能之间的正相关关系。实验表明, $lr=0.001$ (0.2107) 和 $lr=0.0005$ (0.2052) 均不如默认的 $lr=0.01$ (0.2347), 说明在当前数据集规模下, 较大的学习率有助于模型在有限训练轮数内充分探索参数空间。

(5) 证明了模型规模并非越大越好。YOLOv8-Small (11.14M 参数) 的 Best mAP50 (0.2272) 低于 YOLOv8-Nano (3.01M, 0.2347), 为轻量级模型在中小规模数据集上的应用提供了实证支持。

5.2 未来展望

尽管本实验取得了一系列有意义的成果, 但仍有多个方向值得进一步探索:

(1) 组合优化策略。本实验采用单变量调优方法, 未来可探索多超参数的组合优化, 如“大图 ($imgsz=1280$) + 大批量 ($batch=16$)”或“大图 + 更大学习率”等组合, 有望实现精度和泛化性的协同提升。

(2) 引入注意力机制。借鉴 Li 等人 (2022) 的工作, 在 YOLOv8 骨干网络中嵌入 SE (Squeeze-and-Excitation) 或 CBAM (Convolutional Block Attention Module) 注意力模块, 有望进一步提升模型对小目标人眼的感知能力。

(3) 知识蒸馏。利用 YOLOv8-Large 等大模型作为教师网络, 通过知识蒸馏将大模型的知识迁移到轻量级的 YOLOv8-Nano 学生网络中, 在不增加推理成本的前提下提升检测精度。

(4) 自动化超参数搜索。采用 Optuna、Hyperopt 等自动化超参数优化框架, 在多维超参数空间中进行贝叶斯优化或进化搜索, 有望发现超越人工经验的更优配置。

(5) 跨数据集泛化验证。在 CEW (Closed Eyes in the Wild) 或 MRL Eye Dataset 等其他人脸/眼部数据集上验证最优超参数配置的泛化能力, 进一步确认研究结论的普适性。

第二章 眨眼检测方法设计

第一节 核心方法创新

1 引言

眨眼是人类眼部最基本且频繁的行为之一，其频率、持续时间与形态变化蕴含着丰富的生理与心理信息。正常成年人每分钟眨眼约 15 至 20 次，每次持续时间约 100 至 400 毫秒。眨眼行为的异常变化——如频率显著降低、持续时间延长或出现部分闭合（微眨眼）——往往与疲劳、注意力涣散、干眼症、神经系统疾病等状态密切相关。因此，高精度的眨眼检测在智能交通（驾驶员疲劳预警）、虚拟现实（眼动追踪与注视估计）、医疗诊断（神经系统评估）以及人机交互（表情识别与意图推断）等领域均具有广泛的应用价值。

传统的眨眼检测方法主要依赖于手工特征工程与启发式规则。其中，基于面部 landmarks 的眼睑纵横比（Eye Aspect Ratio, EAR）方法由 Soukupova 与 Cech 于 2016 年提出，通过计算上下眼睑关键点的距离比值来判断眨眼状态。然而，EAR 方法对 landmarks 检测精度高度敏感，在面部遮挡、头部大幅旋转或低光照条件下易出现误检与漏检。此外，基于眨眼行为的生理特征，如眼睑运动速度、闭合幅度等统计量，也被用于构建阈值分类器，但这类方法对个体差异的鲁棒性较差，难以泛化到不同人群与场景。

近年来，随着深度学习技术的迅猛发展，数据驱动的端到端眨眼检测方法逐渐成为主流研究范式。基于卷积神经网络（CNN）的方法通过直接从原始图像中学习判别性特征，有效规避了手工特征的不稳定性问题。然而，眨眼本质上是一个动态时序过程：从眼睑张开到完全闭合再到重新张开，构成了一个完整的时序事件。因此，仅依赖单帧图像的 CNN 方法难以捕获这一动态变化的完整上下文，对快速眨眼或部分眨眼（微眨眼）的检测能力不足。

为引入时序建模能力，研究者们提出了多种基于视频序列的检测方法。3D 卷积神经网络（3D CNN）通过将时间维度直接纳入卷积核的感受野，实现了空间特征与时序特征的同步耦合学习。Tran 等人提出的 C3D 以及后续改进的 I3D、R3D 等架构，展示了 3D CNN 在视频理解中的强大能力。然而，3D CNN 的参数量与计算复杂度远高于 2D CNN，且其固定的时空感受野对于眨眼这类短时、细粒度的时序事件缺乏足够的灵活性。基于注意力机制的 Transformer 模型，如 ViT 及其时序扩展

版本 TimeSformer，通过自注意力机制捕获全局时序依赖，但其计算复杂度与序列长度呈平方关系，对于高频采样的视频数据效率有限。

2023 年底，Gu 与 Dao 提出了 Mamba 架构——一种基于选择性状态空间模型（Selective State Space Model, S6）的线性时序序列建模方法。Mamba 通过输入依赖的状态矩阵选择机制，使得模型在保留线性时间复杂度的同时，具备了与 Transformer 相媲美的上下文建模能力。然而，Mamba 的原始设计为单向序列建模，无法充分利用未来的时序信息，这对于需要精确定位事件边界的视频分析任务而言是一个关键瓶颈。

针对上述问题，本文提出了以 BiMamba（双向多尺度时序 Mamba）为核心的网络设计体系。本文的核心贡献可以概括为以下四个方面：（1）双向多尺度时序建模框架。将 Mamba 的单向时序建模扩展为双向结构，通过正向与反向两条独立的状态空间路径，同时利用过去与未来的上下文信息，消除了眨眼起始与终止边界定位的延迟。引入多尺度空洞卷积分支（dilation=1, 3, 5）并行捕获不同时间尺度的眼睑运动模式。（2）空间-时序解耦的模块化架构。采用 2D CNN 逐帧提取空间特征，再由 Mamba 进行时序建模的解耦设计范式。进一步探索了 ShuffleNetV2 作为高效空间骨干的替代方案。（3）多路径网络升级体系。在核心 BiMamba 架构的基础上，从 MIL 聚合策略、多尺度动态门控、运动感知损失函数三个维度进行系统性升级。DualMIL 头通过 Max+Mean 双分支门控融合，在峰值检测灵敏度与全局鲁棒性之间取得平衡；时序注意力门控根据局部运动强度动态调整多尺度分支权重；运动感知约束损失在特征空间中施加眨眼散度与非眨眼抑制，直接驱动模型学习更区分性的时序动态特征。（4）完整的消融实验与对照分析。构建了 7 个网络变体，在统一的裁剪眼部帧序列数据集上进行了系统性训练与测试，所有模型均报告 Recall、Precision 与 F1 三项核心指标。

2 相关工作

2.1 眨眼检测方法

眨眼检测方法的发展历程可以大致划分为传统手工特征阶段、深度学习分类阶段以及视频序列建模阶段。在传统手工特征阶段，Soukupova 与 Cech 提出的基于面部 landmarks 的眼睑纵横比（EAR）方法是里程碑式的工作。该方法通过计算上下眼睑六个关键点的几何关系，将眨眼检测转化为一个简单阈值判断问题。EAR 方法的优势在于无需训练数据，计算开销极低，适合实时部署。然而，其对关键点检

测的依赖使其在面对面部遮挡、光照变化、头部姿态变化等实际场景时鲁棒性不足。后续研究通过融合额外的几何特征（如眼睑轮廓曲率、瞳孔可见度）以及时序统计量（如眨眼持续时间、闭合速度）来提升检测精度，但本质上都受限于手工特征设计的表达能力上限。

进入深度学习时代，基于 CNN 的单帧图像分类方法成为主流。这类方法将裁剪后的眼部区域输入一个 2D CNN，直接输出眨眼/非眨眼的二分类结果。代表性的工作包括基于 VGG、ResNet 等经典骨干网络的迁移学习方案。单帧方法的优势在于模型简单、推理速度快，但其核心局限在于完全忽略了眨眼作为动态事件的时序属性。一个快速眨眼在单帧上可能与正常睁眼的形态差异极小，而一个持续睁眼过程中恰好眨眼的眼睑闭合帧又可能被误判为正例。因此，单帧方法在 Recall 与 Precision 的权衡上往往难以达到理想的平衡。

为弥补单帧方法的不足，基于视频序列的建模方法应运而生。3D CNN 通过在空间维度之外引入时间维度，利用三维卷积核同时捕获局部时空特征，在动作识别与视频分类领域取得了显著进展。Tran 等人提出的 C3D 以及后续改进的 I3D、R3D 等架构，展示了 3D CNN 在视频理解中的强大能力。然而，3D CNN 的参数量与计算复杂度远高于 2D CNN，且其固定的时空感受野对于眨眼这类短时、细粒度的时序事件缺乏足够的灵活性。时序卷积网络（TCN）通过一维卷积在时间轴上滑动，以因果卷积或空洞卷积的方式建模序列依赖。与 RNN 相比，TCN 具有更稳定的梯度传播与更高的并行化效率。然而，TCN 的上下文建模能力受限于卷积核的固定感受野，对于眨眼这类短序列事件（通常仅 13 帧），TCN 的感受野设计需要非常精细的调整。基于注意力机制的 Transformer 模型，如 ViT 及其时序扩展版本 TimeSformer，通过自注意力机制捕获全局时序依赖，但其计算复杂度为 $O(T^2)$ ，对于长序列而言开销巨大。

2.2 状态空间模型与 Mamba

状态空间模型（State Space Model, SSM）是一类源于控制论与信号处理领域的数学框架，用于描述动态系统的状态演化。在深度学习中，SSM 被用于序列建模，通过将序列映射为隐状态的连续演化来捕获长期依赖。早期的结构化状态空间模型（S4）由 Gu 等人提出，通过参数化状态矩阵为低秩结构（HiPP0 初始化），实现了对长序列的高效建模，其计算复杂度为线性 $O(T)$ 。然而，S4 的状态转移矩阵与输入无关，这意味着模型无法根据输入内容自适应地选择性地关注或忽略信息，限制了其表达能力。

2023 年, Gu 与 Dao 提出了 Mamba 架构, 通过引入选择性机制 (Selection Mechanism) 从根本上解决了上述问题。Mamba 的核心思想是: 使状态矩阵的参数 (A, B, C, D) 依赖于当前输入, 从而允许模型根据输入内容选择性地将信息传播到状态或遗忘。具体而言, Mamba 将输入序列通过线性投影生成 B、C 矩阵与步长参数 Δ , 再通过离散化将连续时间 SSM 转换为离散时间递推形式。这种输入依赖的选择机制赋予了 Mamba 与 Transformer 注意力机制相似的上下文建模能力, 同时保留了线性的计算复杂度与恒定的内存占用。Mamba 的设计中另一个关键组件是硬件感知的并行算法。由于状态空间递推的序列依赖性, 传统实现难以并行化。Mamba 通过扫描 (scan) 操作与关联 (associative) 性质, 实现了在 GPU 上的高效并行计算, 显著提升了训练速度。MambaBlock 将 SSM 层与 MLP 层融合为一个统一的块, 通过残差连接与层归一化构建深度网络。这一简洁高效的设计使 Mamba 在长文本语言建模任务中取得了与 Transformer 相媲美的性能, 同时推理速度提升了 5 倍。

2024 年, Zhu 等人将 Mamba 扩展至视觉领域, 提出了 Vision Mamba (ViM)。ViM 通过引入双向 SSM 机制 (Bidirectional SSM) 与位置嵌入, 将图像分块为序列后输入双向 Mamba 进行全局上下文建模。ViM 在 ImageNet 分类、COCO 检测与分割任务上展现了与 Vision Transformer 相当的性能, 同时计算效率更高。双向 Mamba 的设计在视觉领域被证明是有效的, 因为它允许模型同时利用图像块的前后上下文信息。这一思想直接启发了本文将双向 Mamba 应用于视频时序建模的工作: 眨眼的检测不仅依赖于当前帧的上下文, 还需要“看到”未来帧中眼睑重新张开的过程, 以判断一次完整的眨眼事件。

2.3 多示例学习 (MIL) 在视频分析中的应用

多示例学习 (Multiple Instance Learning, MIL) 是一种弱监督学习框架, 适用于仅有序列级标签、缺少帧级标注的场景。在 MIL 框架中, 一个序列 (包) 由多个实例 (帧) 组成, 若序列被标记为正例 (眨眼), 则其中至少存在一个正例实例; 若序列被标记为负例 (非眨眼), 则所有实例均为负例。这一假设与眨眼检测任务高度契合: 一次眨眼序列中至少有一帧是眼睑完全闭合的, 而非眨眼序列中所有帧均保持睁眼状态。在视频分析与时序动作定位领域, MIL 已被广泛应用。Ren 等人提出的基于提案的 MIL (Proposal-based MIL) 方法, 通过生成候选时序提案并在提案级别进行 MIL 训练, 实现了对未标注视频的弱监督时序动作定位。对于眨眼检测而言, 虽然时序长度较短 (通常 13 帧), 但 MIL 框架仍然具有重要价值:

它允许模型在仅有序列级标签的情况下，为每一帧输出一个 blink 概率，进而通过聚合操作得到序列级预测。这种帧级-序列级的联合建模不仅提供了序列分类能力，还隐式地实现了帧级定位，可用于定位眨眼发生的具体帧区间。在本文的设计中，MIL 框架被作为所有网络（包括 Mamba、BiMamba 及其升级版本，以及 3D CNN）的统一顶层分类范式。每个网络为序列中的每一帧输出一个逐帧评分，然后通过聚合操作（如 max-pool、mean-pool 或门控融合）得到序列级预测。这种设计确保了不同网络之间的公平比较，同时为模型的可解释性提供了基础：通过分析逐帧评分，可以直观地观察模型对眨眼事件的时序定位能力。

2.4 ShuffleNet 与高效网络设计

在移动与嵌入式设备上部署深度学习模型时，网络的计算效率与参数量是重要的考量因素。ShuffleNetV2 由 Ma 等人于 2018 年提出，通过一系列受控实验推导了高效网络设计的实用准则，并据此提出了 Channel Split 与 Channel Shuffle 相结合的轻量化单元。ShuffleNetV2 的核心设计包括：均衡输入输出通道数以降低内存访问开销；使用分组卷积时避免过度分组；减少网络碎片以提升并行度；以及逐元素操作的开销不可忽略。基于这些准则，ShuffleNetV2 在保持与 MobileNet 等轻量化网络相当精度的同时，实现了更高的推理速度。在本文中，ShuffleNetV2 被引入作为 BiMamba 的空间特征提取骨干，以验证解耦架构下空间模块的灵活替换能力，同时探索更高效的空间表征方案。

3 网络设计方法

本文围绕裁剪眼部帧序列的眨眼检测任务，设计了 7 个网络变体，构成了一条从基础时序建模到核心创新、再到多路径升级、最后到时空耦合对照的完整设计动线。所有网络均遵循以下统一的任务设定：输入为裁剪后的眼部帧序列，尺寸为 $(B, 3, T, H, W)$ ，其中 B 为批次大小， $T=13$ 为帧数， $H=W=64$ 为空间分辨率。输出为序列级二分类结果（眨眼/非眨眼），以及可选的逐帧定位评分。所有网络均以 MIL 为顶层分类框架，确保实验的可比性。以下按设计动线逐一详细阐述每个网络的架构原理与创新点。

3.1 问题定义与 MIL 框架

给定一个裁剪眼部帧序列 $X = \{x_1, x_2, \dots, x_T\}$ ，其中每个帧 $x_t \in \mathbb{R}^{(3 \times H \times W)}$ ，眨眼检测任务的目标是学习一个映射函数 $f: X \rightarrow y$ ，其中 $y \in \{0, 1\}$ 为序列级标签（1 表示眨眼，0 表示非眨眼）。由于帧级标签未标注，本文采用多示例学习（MIL）框架对序列进行建模：每个序列被视为一个“包”，其中的

每一帧被视为一个“实例”。若序列标签为 1（正包），则包中至少存在一个正实例（即至少有一帧为眨眼状态）；若序列标签为 0（负包），则所有实例均为负（所有帧均为非眨眼状态）。在 MIL 框架下，每个网络首先为每一帧输出一个逐帧评分 $s_t = g_frame(f_t)$ ，其中 f_t 为第 t 帧的隐藏特征， g_frame 为共享的帧级分类头。随后，序列级预测通过聚合操作得到： $\hat{y} = Pool(\{s_1, s_2, \dots, s_T\})$ ，其中 $Pool$ 表示聚合函数，本文中采用 max_pool 作为默认方案（因为眨眼事件中至少存在一帧具有高度显著的 blink 特征）。对于部分升级网络， $Pool$ 被扩展为更复杂的门控融合策略。序列级损失采用二元交叉熵损失（BCE with logits）： $L_{bce} = -[y \cdot \log(\sigma(\hat{y})) + (1-y) \cdot \log(1-\sigma(\hat{y}))]$ ，其中 σ 为 sigmoid 函数。所有网络共享这一统一的 MIL 顶层框架，仅在空间特征提取与序列建模模块上存在差异。

3.2 基础时序建模：单向 Mamba (Mamba)

本文的第一个网络是一个基于单向 Mamba 的时序建模基线，其设计目标是在验证 Mamba 架构在眨眼检测任务中的适用性，同时建立后续双向扩展的对比基准。该网络的整体架构遵循空间-时序解耦的设计范式，由三个核心模块组成：轻量级 2D 空间骨干、单向 Mamba 时序建模层与 MIL 分类头。

空间特征提取。轻量级 2D 骨干（Light2DBackbone）由 4 个步长卷积层串联构成：第一层将 3 通道输入通过 3×3 卷积（stride=2, padding=1）映射至 32 通道，随后经过批归一化与 ReLU 激活；第二层将 32 通道扩展至 64 通道，同样采用 3×3 步长卷积；第三层扩展至 128 通道；第四层将 128 通道映射至目标特征维度 256，随后经过批归一化、ReLU 与自适应平均池化（AdaptiveAvgPool2d(1)），输出展平后的 256 维特征向量。该骨干的空间下采样路径为： $64 \rightarrow 32 \rightarrow 16 \rightarrow 8 \rightarrow 1$ ，通过逐层 stride=2 的卷积实现 4 倍空间下采样。整个骨干仅包含 4 个卷积层，参数量极小，适合作为快速实验的基线。值得注意的是，该骨干以逐帧方式独立处理每一帧，即输入序列 $(B, 3, T, H, W)$ 被 reshape 为 $(B \cdot T, 3, H, W)$ 后送入骨干，输出 $(B \cdot T, 256)$ 的空间特征，再 reshape 回 $(B, T, 256)$ 。这种“共享权重、逐帧独立”的处理方式确保了空间特征提取与序列长度无关，为后续时序建模提供了统一的特征空间。

时序建模。经过空间特征提取后，每一帧被表示为一个 256 维的特征向量，序列被表示为特征矩阵 $(B, T, 256)$ 。该特征首先经过一个线性投影层（ $nn.Linear(256, 256)$ ），然后送入两层堆叠的单向 Mamba 模块。每层 Mamba 的

参数配置为：d_model=256（输入维度），d_state=16（SSM 状态维度），d_conv=4（因果卷积核大小），expand=2（扩展因子）。Mamba 的选择性机制通过输入依赖的 B、C 矩阵与 Δ 参数，使得模型能够根据当前帧内容选择性地将信息传播到隐状态或遗忘。两层堆叠的 Mamba 通过残差连接与层归一化（LayerNorm）构建深度时序编码器。单向 Mamba 的时序处理是因果的：第 t 帧的输出仅依赖于第 1 至 t 帧的输入，无法利用未来的上下文信息。这一特性在自然语言处理中（如自回归语言建模）是必需的，但对于视频分析任务——尤其是需要精确定位事件边界的眨眼检测——则可能导致定位延迟：模型在判断当前帧是否为眨眼状态时，无法参考后续帧中眼睑重新张开的信息，从而降低了边界定位的精度。

MIL 分类头。经过 Mamba 时序建模后，输出的时序特征（B, T, 256）被送入共享的帧级分类头（nn.Linear(256, 1)），为每一帧输出一个 logit。随后，通过 max-pool 操作在序列维度上聚合所有帧的评分，取最大评分作为序列级预测：seq_logits = max(frame_scores, dim=1)。这一设计的直觉是：若一个序列包含眨眼事件，则其中至少存在一帧（通常是眼睑完全闭合的帧）具有极强的 blink 特征，该帧的评分会显著高于其他帧，max-pool 操作能够灵敏地捕获这一峰值信号。对于非眨眼序列，所有帧的评分均应较低，max-pool 输出一个较小的值。序列级损失为 BCE with logits，训练时仅使用序列级标签进行监督，帧级评分的优化是隐式的。

该基线网络的设计简洁明了，其核心价值在于验证了 Mamba 架构在短序列视频分类任务中的可行性。然而，其单向因果结构限制了模型对完整时序上下文的利用能力，为后续双向扩展提供了明确的改进方向。

3.3 核心创新：双向多尺度时序 Mamba (BiMamba)

本文的核心创新网络是双向多尺度时序 Mamba (BiMamba + MS-Temba)，其设计目标是在保留 Mamba 线性时间复杂度优势的同时，通过双向建模与多尺度并行分支，实现对眨眼事件时序动态的精细化刻画。该网络在整体架构上延续了空间-时序解耦的范式，但在时序建模模块上进行了根本性的升级：引入双向 SSM 机制与多尺度空洞卷积分支。

双向 Mamba 是本文解决单向 Mamba 因果局限性问题的关键设计。具体实现上，BidirectionalMamba 模块包含两条独立的状态空间路径：正向路径（Forward Mamba）与反向路径（Backward Mamba）。正向路径与单向 Mamba 完全一致：对输入序列按原始时间顺序（从第 1 帧到第 T 帧）进行状态空间递推，输出正向时序特

征 fw_out 。反向路径则首先将输入序列在时间维度上反转 (`torch.flip, dims=[1]`)，然后送入另一组独立的 Mamba 层进行状态空间递推，得到反向时序特征后再将其在时间维度上翻转回原始顺序 (bw_out)。

双向路径的合并策略支持三种模式：相加 (`add`)、拼接投影 (`concat`) 与门控融合 (`gate`)。在默认配置中，本文采用相加模式： $out = fw_out + bw_out$ 。相加模式的优势在于计算简洁，且不改变特征维度，便于后续模块的直接处理。在门控模式下，模型通过 `sigmoid` 门控动态地权衡正向与反向信息的重要性： $gate = \text{sigmoid}(\text{Linear}(\text{concat}([fw_out, bw_out])))$ ， $out = gate * fw_out + (1 - gate) * bw_out$ 。拼接投影模式则先将两个方向的特征拼接后通过线性层投影回原始维度。在本文的实验中，默认使用相加模式，以确保与后续升级模块的兼容性。

双向 Mamba 的引入从根本上解决了眨眼边界定位延迟的问题。以一次典型眨眼为例：假设第 6 帧为眼睑完全闭合的峰值帧，正向路径在处理第 6 帧时，可以整合第 1 至 6 帧的张开→闭合过程；反向路径在处理第 6 帧时（对应反向序列的第 $T-6+1$ 帧），可以整合第 6 至 T 帧的闭合→张开过程。两条路径的融合使得第 6 帧的最终特征同时包含了前后两个方向的完整上下文信息，从而能够更精确地判断该帧是否为眨眼峰值。这种“双向感知”能力对于区分眨眼与眼部其他短暂运动（如眼球快速转动、短暂皱眉等）至关重要，因为这些干扰事件通常不具备完整的眼睑闭合-张开周期。

眨眼事件在时序尺度上呈现出显著的多样性。正常快速眨眼通常仅持续 100 至 200 毫秒，在 25 帧/秒的视频中对应约 2 至 5 帧；而疲劳或干眼症导致的慢速眨眼或微眨眼可能持续 300 至 500 毫秒，对应约 7 至 12 帧。此外，不同个体的眨眼速度、幅度与习惯均存在差异。单一尺度的时序建模难以同时适应这些多样化的时序模式。为解决这一问题，本文提出了多尺度时序块 (Multi-Scale Temporal Block, MS-Temba)，通过并行分支的方式同时捕获不同时间尺度的眼睑运动特征。

MS-Temba 包含三个并行的分支，每个分支由一个空洞卷积 (`Dilated Conv1d`) 与一个双向 Mamba 模块串联组成。三个分支的空洞率分别为 $dilation=1$ 、 $dilation=3$ 与 $dilation=5$ ，卷积核大小均为 3。空洞率的选择基于以下理论分析：对于 13 帧的序列，空洞率 $d=1$ 时卷积的感受野为 3 帧，对应约 120 毫秒的瞬时时间窗，适合捕获快速眨眼的局部峰值； $d=3$ 时感受野扩展为 7 帧

($dilation \times (kernel-1) + 1$)，对应约 280 毫秒的时间窗，适合捕获中等速度的眨眼过程； $d=5$ 时感受野扩展为 11 帧，对应约 440 毫秒的时间窗，适合捕获慢速微

眨眼或眼睑疲劳性渐进闭合。所有空洞卷积均采用深度可分离卷积

($\text{groups}=\text{d_model}$) 以减少计算量, 并通过 $\text{padding}=\text{dilation}\times(\text{kernel}/2)$ 保持序列长度不变。

每个分支的完整处理流程为: 输入特征 (B, T, D) 首先经过空洞卷积 ((B, D, T) $\rightarrow$ conv $\rightarrow$ (B, D, T) $\rightarrow$ permute $\rightarrow$ (B, T, D)), 然后通过 SiLU 激活函数与层归一化, 送入双向 Mamba 模块进行全局序列建模, 最后通过残差连接与原始输入相加。空洞卷积提供了局部时序上下文提取能力, 而双向 Mamba 则提供了全局序列建模能力, 二者的组合使得每个分支在特定尺度上同时具备局部与全局的感知能力。

三个分支的输出通过融合模块进行聚合。融合模块首先将三个分支的输出沿特征维度拼接 ((B, T, $D\times 3$)), 然后通过一个线性投影层与一个层归一化层映射回原始维度 (B, T, D)。此外, MS-Temba 引入了可学习的逐分支缩放权重

(scale_weights), 通过 sigmoid 函数归一化后作为各分支输出的加权系数: $w_i = \text{sigmoid}(\text{scale_weights}[i])$ 。这些权重在训练过程中自动学习, 使模型能够根据数据分布自适应地调整三个分支的相对重要性。默认配置下, 所有分支的初始权重均等 (权重为 1), 由训练过程动态优化。

BiMamba 整体网络 (BiMultiScaleMambaBlink_MIL) 的完整流程如下: 输入 (B, 3, 13, 64, 64) 首先通过共享的 Light2DBackbone 逐帧提取空间特征, 输出 (B, 13, 256); 然后经过输入层归一化 (LayerNorm) 送入 MS-Temba 进行多尺度双向时序建模, 输出 (B, 13, 256); 再经过输出层归一化, 送入帧级分类头得到逐帧评分 (B, 13); 最后通过 max-pool 聚合得到序列级预测 (B, 1)。整个网络的核心参数配置为: $\text{feat_dim}=256$, $\text{d_state}=16$, $\text{d_conv}=4$, $\text{expand}=2$, $\text{dilations}=(1, 3, 5)$, $\text{num_mamba_layers}=1$, $\text{merge}=\text{"add"}$ 。

与基线 Mamba 相比, BiMamba 在保持参数量增长可控的前提下, 实现了两个维度的关键升级: 双向上下文感知消除了边界定位延迟; 多尺度并行分支实现了对多样化眨眼时序模式的覆盖。这两项创新共同构成了本文网络设计体系的核心, 后续所有升级网络均在此基础上进行扩展。

3.4 网络升级一: ShuffleNetV2 空间特征提取 (BiMamba-SN)

BiMamba-SN 网络 (BiMultiScaleMambaShuffleNet_MIL) 的设计动机是探索解耦架构下空间特征提取模块的灵活替换能力。BiMamba 的核心创新集中在时序建模模块, 而空间特征提取模块仍沿用轻量级的 4 层步长卷积骨干。虽然该骨干足够简

洁，但其空间表征能力相对有限，可能无法充分提取眼部区域的细微纹理特征（如睫毛边缘、眼睑轮廓、虹膜细节等）。ShuffleNetV2 作为一种高效的轻量化网络架构，在保持极低计算开销的同时提供了更强的空间特征表征能力，是替换空间骨干的理想候选。

ShuffleNetV2 骨干的设计严格遵循原始论文提出的四项高效网络设计准则。其架构由 Stem（初始下采样）、Stage2、Stage3、Stage4 与 Conv5（输出投影）五个阶段组成。Stem 阶段将 3 通道输入通过 3×3 卷积（stride=2, padding=1）映射至 24 通道，随后经过批归一化与 ReLU 激活，输出尺寸为 $(B \cdot T, 24, 32, 32)$ 。Stage2 采用一个 ShuffleV2Block（stride=2），将通道数从 24 扩展至 48，空间尺寸降至 16×16 。Stage3 包含三个 ShuffleV2Block：第一个 stride=2 下采样块将 48 通道扩展至 96，空间尺寸降至 8×8 ；后两个 stride=1 基本块保持通道数与空间尺寸不变。Stage4 采用一个 stride=2 的 ShuffleV2Block，将 96 通道扩展至 192，空间尺寸降至 4×4 。Conv5 阶段通过 1×1 卷积将 192 通道映射至目标特征维度 256，随后经过批归一化、ReLU 与全局平均池化，输出 $(B \cdot T, 256)$ 的特征向量。

ShuffleV2Block 的核心机制是 Channel Split 与 Channel Shuffle。对于 stride=1 的基本块，输入特征被沿通道维度均分为两半：一半通过恒等映射（identity）保持不变，另一半通过 1×1 卷积 $\rightarrow 3 \times 3$ 深度可分离卷积 $\rightarrow 1 \times 1$ 卷积的瓶颈结构进行变换，最后两半特征拼接并通过 Channel Shuffle 操作实现跨组信息交互。对于 stride=2 的下采样块，输入特征不再分割，而是分别通过两个不同的路径：一个路径为 3×3 深度可分离卷积（stride=2） $\rightarrow 1 \times 1$ 卷积；另一个路径为 1×1 卷积 $\rightarrow 3 \times 3$ 深度可分离卷积（stride=2） $\rightarrow 1 \times 1$ 卷积，最后拼接并 Channel Shuffle。这种设计在保持通道均衡的同时实现了高效的下采样与特征变换。

在 BiMamba-SN 中，ShuffleNetV2 骨干替换原有的 Light2DBackbone，而时序建模模块（MS-Temba）与分类头完全保持不变。这种“即插即用”的替换方式充分验证了解耦架构的灵活性：空间模块的升级不影响时序模块的设计，反之亦然。通过实验对比，可以评估空间特征提取能力的提升对最终检测性能的贡献，从而为实际部署场景（如嵌入式设备上需要更高效的骨干）提供选型依据。

3.5 网络升级二：Max+Mean 双分支 MIL 聚合 (BiMamba-Dual)

BiMamba-Dual 网络 (BiMultiScaleMambaDual_MIL) 的核心升级在于序列级聚合策略的改进。原始 BiMamba 采用简单的 max-pool 作为 MIL 聚合操作：

$\text{seq_logits} = \max(\text{frame_scores})$ 。虽然 max-pool 在理论上能够捕获序列中的最强 blink 信号，但其在实践中存在两个显著的局限性：第一，对异常值敏感。若序列中存在某一帧因噪声（如光照闪烁、快速运动模糊）而产生异常高的评分，max-pool 会将该噪声帧误判为眨眼峰值，导致高 Recall 但低 Precision 的检测倾向。第二，忽略时序分布。max-pool 仅关注单个峰值帧，忽略了其余帧的评分分布。对于一次真实的眨眼事件，通常有连续 2 至 4 帧的评分较高（对应眼睑闭合到张开的过程），这种时序分布特征本身也是一个强判别信号，但 max-pool 无法利用这一信息。

为克服上述问题，本文提出了 DualMILHead——一种基于 Max+Mean 双分支门控融合的 MIL 聚合头。DualMILHead 包含三个核心组件：共享帧级分类头、Max 分支、Mean 分支与门控融合模块。共享帧级分类头与原始 BiMamba 一致

$(\text{nn.Linear}(256, 1))$ ，为每一帧输出一个评分。Max 分支通过 max 操作提取序列中的峰值评分： $\text{max_logit} = \max(\text{frame_scores}, \text{dim}=1)$ ，该分支对孤立的高显著度帧敏感，适合捕获快速、尖锐的眨眼事件。Mean 分支通过 mean 操作计算序列评分的全局平均值： $\text{mean_logit} = \text{mean}(\text{frame_scores}, \text{dim}=1)$ ，该分支对时序分布的“整体活跃度”敏感，适合捕获持续时间较长、多帧均有较高评分的渐进式眨眼事件。门控融合模块通过一个两层的 MLP（输入维度=512=256×2，隐藏维度=64，输出维度=1）动态地为每个样本计算融合权重： $\text{gate} = \text{sigmoid}(\text{MLP}(\text{concat}([\text{max_feat}, \text{mean_feat}])))$ ，其中 max_feat 与 mean_feat 分别为时序特征在序列维度上的最大值与均值 $(B, 256)$ 。最终融合公式为： $\text{seq_logits} = \text{gate} \times \text{max_logit} + (1 - \text{gate}) \times \text{mean_logit}$ 。

门控融合的设计赋予了模型根据样本特性自适应选择聚合策略的能力。对于具有尖锐峰值、快速闭合-张开的眨眼事件，时序特征分布呈现“尖峰状”，max_feat 显著大于 mean_feat，门控倾向于接近 1，信任 Max 分支；对于渐进式、持续时间较长的疲劳眨眼，时序特征分布较为平坦，max_feat 与 mean_feat 差异较小，门控倾向于接近 0.5，均衡地融合两个分支。这种自适应机制在理论上能够同时提升 Precision（通过 Mean 分支过滤噪声尖峰）与 Recall（通过 Max 分支捕获微弱峰值）。

值得注意的是，DualMILHead 的输入不仅包含逐帧评分，还包含时序特征的统计量（max_feat 与 mean_feat），这使得门控决策不仅基于“评分的高低”，还基于“特征分布的形态”，从而具有更强的判别能力。在整体架构上，BiMamba-Dual 的其余部分（空间骨干、MS-Temba、帧级头）与原始 BiMamba 完全一致，仅将序列级聚合操作从 max-pool 替换为 DualMILHead，形成了一个聚焦于 MIL 策略升级的精准消融实验。

3.6 网络升级三：运动驱动的时序注意力门控 (BiMamba-Gated)

BiMamba-Gated 网络 (BiMultiScaleMambaGated_MIL) 的升级聚焦于 MS-Temba 多尺度分支融合策略的动态化。在原始 MS-Temba 中，三个分支的融合权重是通过可学习的标量参数 (scale_weights) 经 sigmoid 归一化后施加的。这些权重是全局的、静态的：对于所有输入序列、所有时间步，三个分支的相对重要性是固定的。然而，不同序列的眨眼动态模式差异显著：快速眨眼在运动特征上表现为相邻帧之间的剧烈变化，应在 dilation=1 的瞬时分支上获得更高权重；慢速微眨眼则表现为帧间变化的渐进性，应在 dilation=5 的慢速分支上获得更高权重。静态权重无法适应这种序列级、帧级的动态差异。

为解决这个问题，本文提出了 TemporalAttentionGate——一种运动驱动的动态时序注意力门控机制。TemporalAttentionGate 的核心思想是：根据输入序列的局部运动强度，为每个时间步、每个分支动态计算融合权重。具体实现上，TemporalAttentionGate 包含两个子模块：局部运动检测器与注意力映射器。局部运动检测器是一个深度可分离的 1D 卷积 (kernel_size=7, padding=3, groups=d_model)，在时间维度上滑动，提取相邻帧之间的特征变化模式。卷积核大小选择为 7 帧，对应约 280 毫秒的局部时间窗，能够捕获一个完整眨眼周期的大部分动态信息。注意力映射器是一个两层的 MLP (输入维度=256, 隐藏维度=64, 输出维度=3)，将运动检测器的输出映射为三个分支的注意力 logits，然后通过 softmax 在分支维度上归一化，得到每个时间步的三支权重：weights = softmax(MLP(motion_features), dim=-1)，输出形状为 (B, T, 3)。

在 GatedMS_Temba 中，动态门控机制替代了原始 MS-Temba 的静态 scale_weights。处理流程为：首先通过 TemporalAttentionGate 计算每个时间步的三支权重 (B, T, 3)；然后每个分支独立处理输入特征，得到三支输出 (B, T, D)；接着将每个分支的输出乘以对应的时间步权重并求和：fused =

$\text{sum}_i(\text{branch}_i \times \text{weights[:, :, i:i+1]})$ ；最后通过拼接投影融合模块（与原始 MS-Temba 一致）将融合特征映射回 (B, T, D)。

这一设计的核心优势在于实现了“帧级自适应”：序列中的不同时间步可以根据其局部运动特征自动选择最合适的尺度分支。例如，在眨眼起始阶段（眼睑快速闭合），局部运动强度大， $\text{dilation}=1$ 分支的权重会显著升高；在眨眼峰值阶段（眼睑完全闭合），运动趋于静止，权重可能向 $\text{dilation}=3$ 或 5 分支偏移；在眨眼终止阶段（眼睑重新张开），运动再次增强， $\text{dilation}=1$ 分支重新获得优势。这种动态切换机制使得模型能够更精确地追踪眨眼事件的完整时序过程，而非仅依赖全局静态的尺度偏好。

3.7 网络升级四：运动感知特征约束损失 (BiMamba-Motion)

BiMamba-Motion 网络 (BiMultiScaleMambaMotion_MIL) 的升级方向与前三个网络不同：前三个网络聚焦于网络架构的改进（空间骨干、MIL 聚合头、多尺度门控），而 BiMamba-Motion 聚焦于损失函数的设计，通过引入运动感知特征约束，在特征空间中直接驱动模型学习更区分性的眨眼动态模式。这一设计受到了基于眼睑运动分析的眨眼检测方法的启发：传统方法通过计算帧间像素差异或特征变化来检测眨眼，其核心假设是眨眼事件伴随着显著的眼睑运动，而非眨眼序列则保持相对稳定。本文将这一直觉形式化为两个可微分的约束损失项，直接施加在 MS-Temba 输出的时序特征序列上。

整体架构上，BiMamba-Motion 与原始 BiMamba 基本一致（空间骨干、MS-Temba、帧级头、max-pool），唯一的区别是在 forward 函数中增加了 return_features 选项，用于在训练时暴露时序特征（post-LayerNorm, pre-frame-head）供损失函数计算。训练时采用 motion_aware_bce_loss 替代标准的 BCE with logits 损失。

motion_aware_bce_loss 包含三个组成部分：标准 BCE 分类损失 L_{bce} 、眨眼散度损失 L_{div} 与非眨眼抑制损失 L_{sup} 。总损失公式为： $L_{\text{total}} = L_{\text{bce}} + \lambda_{\text{blink}} \times L_{\text{div}} + \lambda_{\text{nonblink}} \times L_{\text{sup}}$ ，其中 $\lambda_{\text{blink}}=0.1$ ， $\lambda_{\text{nonblink}}=0.05$ 为超参数。

眨眼散度损失 (L_{div}) 的设计目标是最大化眨眼序列中相邻帧之间的特征变化。其数学形式为： $L_{\text{div}} = \text{ReLU}(\text{margin} - ||f_{\{t+1\}} - f_t||_2)$ ，其中 $\text{margin}=0.5$ ， f_t 为第 t 帧的 L2 归一化时序特征。该损失仅在正例 (blink) 样本

上计算。对于真实眨眼序列，眼睑从张开到闭合再到张开的过程应该伴随着显著的形态变化，因此相邻帧之间的特征差异应该较大。如果模型在眨眼序列上学习到的特征过于平滑（即相邻帧特征差异很小），则意味着模型未能充分编码眨眼动态， L_{div} 会惩罚这种情况。通过最小化 L_{div} ，模型被迫在特征空间中放大眨眼序列的帧间动态变化，从而增强对眨眼模式的区分性。

非眨眼抑制损失 (L_{sup}) 的设计目标是最小化非眨眼序列中相邻帧之间的特征变化。其数学形式为： $L_{sup} = ||f_{\{t+1\}} - f_t||_2$ ，该损失仅在负例 (non-blink) 样本上计算。对于非眨眼序列，理论上所有帧的眼部状态保持稳定（完全睁眼），因此相邻帧之间的特征差异应该很小。然而，实际采集的数据中，非眨眼序列可能包含头部运动、光照变化、眼球转动等干扰因素，这些因素会导致帧间像素差异，进而被模型编码为特征变化。 L_{sup} 通过惩罚非眨眼序列中的特征变化，迫使模型忽略这些与眨眼无关的动态干扰，专注于真正具有判别性的眼睑运动模式。

两项约束损失的组合形成了一个“推-拉” (push-pull) 机制：对于眨眼序列，特征被“拉开”（增大帧间差异）；对于非眨眼序列，特征被“推进”（减小帧间差异）。这种在特征空间中的显式约束，与分类损失在标签空间中的隐式优化形成互补，共同驱动模型学习更鲁棒、更区分性的时序动态特征表示。值得注意的是， L_{div} 与 L_{sup} 的计算基于 L_2 归一化后的特征，确保距离度量在 $[0, 2]$ 的范围内，避免特征幅值变化对损失尺度的影响。此外，当序列长度 $T < 2$ 时（单帧序列），无法计算帧间差异，此时 L_{div} 与 L_{sup} 均为 0，仅保留 BCE 损失。

3.8 对照网络：3D CNN 时空耦合 (CNN3D)

为全面评估本文提出的空间-时序解耦设计范式 (2D CNN + Mamba) 相较于传统的时空耦合设计范式 (3D CNN) 的优劣，本文构建了基于 3D ResNet18 的时空耦合对照网络 (Light3DResNet18_MIL)。该网络的设计目标是提供一个在参数量、计算复杂度与架构复杂度上可比的 3D CNN 基线，以公平的实验条件检验两种范式的性能差异。

3D CNN 的核心思想是将时间维度 T 直接纳入卷积核的滑动维度，通过三维卷积核 (spatial $H \times W$ + temporal T) 同时提取局部时空特征。与 2D CNN 逐帧独立处理不同，3D CNN 的每一层输出同时依赖于当前帧及其邻帧的空间信息，从而在网络的每一层都实现了时空耦合。本文采用的 Light3DResNet18 是一个轻量化的 3D ResNet18 变体，其基础通道数设置为 32（而非标准 ResNet18 的 64），以降低参数量。

Light3DResNet18 的架构由以下部分组成：初始卷积层（conv1）采用 3D 卷积核（ $3 \times 7 \times 7$ ），其中时间维度核大小为 3、空间维度核大小为 7×7 ， $\text{stride}=(1, 2, 2)$ ， $\text{padding}=(1, 3, 3)$ 。这一设计保留了时间维度的原始长度（ $\text{stride}=1$ ），同时实现了空间的初始下采样。随后经过批归一化、ReLU 与 3D MaxPool（ $\text{kernel_size}=(1, 3, 3)$ ， $\text{stride}=(1, 2, 2)$ ），输出尺寸为（B, 32, T, 16, 16）。接下来是四个残差层（layer1 至 layer4），每个层由 2 个 BasicBlock3D 组成。BasicBlock3D 包含两个 $3 \times 3 \times 3$ 的 3D 卷积层，中间插入批归一化与 ReLU，并通过残差连接实现恒等映射。与标准 2D ResNet 不同的是，3D 残差块的时间维度 stride 固定为 1，以确保整个网络的时间维度始终为 $T=13$ 。四个层的通道数分别为 32、64、128、256，空间维度逐层下采样至 1×1 。最后通过全局自适应最大池化与全连接层输出序列级预测。

为了实现与 MIL 框架的兼容性，Light3DResNet18_MIL 在网络末端增加了一个帧级评分分支。具体而言，在 layer4 的输出（B, 256, T, 1, 1）后，通过空间维度的自适应池化（仅保留时间维度，空间维度压缩至 1×1 ）得到（B, 256, T），然后转置为（B, T, 256），通过一个两层 MLP（ $256 \rightarrow 64 \rightarrow 1$ ）得到逐帧评分（B, T），最后通过 max-pool 聚合得到序列级预测（B, 1）。这种设计确保了 3D CNN 与 Mamba 系列网络在 MIL 框架下的公平比较：两者都输出逐帧评分，都通过 max-pool 聚合，都使用 BCE with logits 损失。唯一的差异在于时空特征提取的方式：3D CNN 采用时空耦合的卷积路径，而 Mamba 系列采用空间-时序解耦的 2D CNN+Mamba 路径。

从计算复杂度角度分析，3D CNN 的卷积操作同时涉及空间与时间维度，其计算量与空间尺寸、时间长度以及通道数均成正比。对于一个（B, C, T, H, W）的 3D 卷积，计算复杂度为 $O(B \times C_{\text{out}} \times T \times H \times W \times K_t \times K_s \times K_s \times C_{\text{in}})$ 。相比之下，空间-时序解耦方案的计算复杂度为 $O(B \times T \times C_{\text{out}} \times H \times W \times K_s \times K_s \times C_{\text{in}}) + O(B \times T \times D \times D_{\text{state}})$ ，其中第一项为 2D CNN 的空间特征提取，第二项为 Mamba 的时序建模。对于短序列（ $T=13$ ），解耦方案的计算量通常显著低于 3D CNN，因为 2D CNN 仅需处理单帧，而 Mamba 的线性复杂度远低于 3D 卷积的立方级复杂度。

此外，3D CNN 的时空感受野是固定且耦合的。3D 卷积核在时间维度上的固定尺寸（如 3 帧）意味着模型只能捕获固定长度的局部时序依赖，对于更长或更短的动态模式缺乏适应性。虽然可以通过堆叠多层卷积扩展感受野，但这种扩展是均匀且缓慢的，难以精确匹配眨眼事件的多样化时序尺度。相比之下，Mamba 系列网络

中的多尺度空洞卷积（dilation=1, 3, 5）与双向 SSM 机制提供了更灵活、更精确的时序建模能力。3D CNN 对照实验的结果将为这一理论分析提供实证支持。

4 实验设置与数据集

4.1 数据集构成

本文的实验基于裁剪眼部帧序列数据集进行。数据集从视频采集的眼部区域中，以固定长度 $T=13$ 帧裁剪出连续的帧序列，每个序列的空间尺寸为 64×64 像素。数据集的标签为序列级二分类标签：1 表示该序列包含至少一次眨眼事件，0 表示该序列不包含任何眨眼事件。数据集的划分采用训练集/验证集/测试集的标准方式，其中测试集包含 439 个样本，其中正例（眨眼）248 个，负例（非眨眼）191 个，正负比例约为 56.5%:43.5%。测试集在所有网络实验中保持完全一致，以确保实验结果的可比性。

4.2 实验环境

所有实验均在统一的 PyTorch 深度学习框架下进行。训练过程使用 Adam 优化器，学习率根据具体网络进行调整。所有网络均采用二元交叉熵损失（BCE with logits）作为序列级分类损失，仅 BiMamba-Motion 网络采用 `motion_aware_bce_loss`。训练时采用早停（Early Stopping）策略监控验证集 F1 分数，保存验证集 F1 最高的模型权重作为最佳检查点。测试时加载最佳检查点，在测试集上计算 Accuracy、Precision、Recall、F1、AUC 与 PR-AUC 六项指标，并绘制 Precision-Recall 曲线。

4.3 网络训练配置

各网络的训练轮数（epochs）与超参数设置如下：Mamba 基线、BiMamba、BiMamba-SN、BiMamba-Motion 与 3D CNN 均训练 50 个 epoch；BiMamba-Dual 与 BiMamba-Gated 训练 70 个 epoch。所有网络的空间特征维度均为 256，Mamba 与 BiMamba 系列的 $d_state=16$ ， $d_conv=4$ ， $expand=2$ 。BiMamba-Gated 的 TemporalAttentionGate 的 $motion_kernel=7$ 。BiMamba-Motion 的 $lambda_blink=0.1$ ， $lambda_nonblink=0.05$ ， $margin=0.5$ 。3D CNN 的 $base_channels=32$ ，采用 4 层残差结构，与 2D ResNet18 保持一致层级深度以提供公平比较。

5 实验结果与分析

5.1 训练过程对比

本节首先分析各网络在训练过程中的验证集指标变化曲线，以评估模型的收敛行为、过拟合倾向与最优 epoch 的选择。图 1 展示了所有 7 个网络的验证集 F1 曲线与验证集 Loss 曲线。从 F1 曲线可以观察到，3D CNN 在训练早期（约第 5 至 15 epoch）迅速达到较高的验证 F1 水平，并在第 36 epoch 达到最佳验证 F1

（0.9126），显示出其强大的时空特征学习能力。BiMamba 的收敛速度相对较慢，但曲线更加稳定，在第 42 epoch 达到最佳验证 F1（0.9020），随后逐渐下降，表明在 50 epoch 附近开始出现轻微过拟合。BiMamba-Dual 与 BiMamba-Gated 由于训练了 70 个 epoch，其曲线展现出更长的优化过程，分别在第 40 epoch 与第 51 epoch 达到最佳验证 F1（均为 0.8932）。值得注意的是，BiMamba-SN 在第 27 epoch 即达到最佳验证 F1（0.8911），是所有网络中收敛最快的之一，这得益于 ShuffleNetV2 更强的空间特征表征能力，使得模型在更少的 epoch 内学到有效的判别特征。BiMamba-Motion 的最佳验证 F1（0.8824）出现在第 27 epoch，而 Mamba 基线的最佳验证 F1（0.8762）出现在第 45 epoch。




图 1 各网络验证集 F1 曲线（左）与验证集 Loss 曲线（右）对比

从 Loss 曲线来看，所有网络的验证 Loss 在训练初期均呈现快速下降趋势，随后逐渐趋于平稳或小幅上升。3D CNN 的验证 Loss 最低且最稳定，反映出其强大的模型容量与拟合能力。BiMamba 系列网络的 Loss 曲线在训练后期出现了不同程度的上升，这是过拟合的典型信号，表明更复杂的时序建模模块在训练数据有限的情况下可能学习到噪声特征。BiMamba-Motion 的 Loss 曲线在训练后期下降最为明显，这可能得益于运动感知损失函数的约束，使得模型在特征空间中学习到更鲁棒的表示。

5.2 测试集指标对比

表 1 汇总了所有 7 个网络在测试集上的核心性能指标。测试集包含 439 个样本，其中 248 个正例（眨眼）与 191 个负例（非眨眼），是一个正负样本相对均衡但略偏斜的数据集。在评估指标上，Accuracy 衡量整体分类正确率，Precision 衡量预测为眨眼时的正确率，Recall 衡量实际眨眼被检测出的比例，F1 为 Precision 与 Recall 的调和平均，AUC 衡量模型排序能力，PR-AUC 衡量 Precision-Recall 曲线下的面积，对正负样本不均衡场景更为敏感。

网络	Accuracy	Precision	Recall	F1	AUC	PR-AUC
BiMamba+Motion	0.8588	0.8444	0.9194	0.8803	0.9022	0.8971
BiMamba	0.8405	0.8423	0.8831	0.8622	0.8747	0.8442
3D CNN	0.8246	0.7918	0.9355	0.8577	0.9009	0.9184
Mamba	0.8018	0.7539	0.9637	0.8460	0.8468	0.8096
ShuffleNetV2+BiMamba	0.7882	0.7645	0.9032	0.8281	0.8516	0.8501
BiMamba+GatedAttn	0.7882	0.7758	0.8790	0.8242	0.8257	0.8259
BiMamba+DualMIL	0.7699	0.7732	0.8387	0.8046	0.8181	0.8117

表 1 各网络测试集性能指标对比（按 F1 降序排列）

从表 1 可以看出，BiMamba-Motion 在以运动感知损失训练后，取得了测试集最优的综合性能：F1 分数最高（0.8803），Accuracy 最高（0.8588），AUC 最高（0.9022）。这一结果表明，运动感知特征约束作为一种无参正则化策略，不仅没有增加模型复杂度，反而通过显式引导时序特征学习运动变化信息，显著提升了泛化性能。基础 BiMamba 的 F1 为 0.8622，Precision 最高（0.8423），说明双向多尺度时序建模框架本身已具备出色的基础能力。3D CNN 的 PR-AUC 达到 0.9184，在所有网络中最高，PR-AUC 最优说明其在不均衡场景下的综合排序能力最强。Mamba 基线在 Recall 上达到了 0.9637，为所有网络最高，表明单向 Mamba 的因果结构对正例（眨眼）的检测极为灵敏，但 Precision 仅为 0.7539，说明其将大量非眨眼样本误判为眨眼，存在较高的假阳性率。

值得注意的是，在四个升级版本中，BiMamba-Motion 表现突出，其 F1（0.8803）不仅超越了基础 BiMamba（0.8622），也成为所有网络中 F1 最优的模型，同时 Accuracy（0.8588）与 AUC（0.9022）也均为最优。这一结果充分说明运动感知损失作为一种“无参正则化”策略的有效性——它在不引入任何额外网络参数的前提下，通过训练过程中对时序特征的显式约束，显著提升了模型的泛化能力。

另外三个升级版本（BiMamba-SN、BiMamba-Dual、BiMamba-Gated）在测试集上的 F1 分数低于基础 BiMamba。这一现象可以从以下角度分析：

（1）数据规模与模型复杂度的不匹配。本实验的数据集规模相对有限（测试集仅 439 个样本），而 BiMamba-SN、BiMamba-Dual 与 BiMamba-Gated 引入了额外的网络参数（如 ShuffleNetV2 的更多通道、DualMILHead 的额外 MLP、TemporalAttentionGate 的卷积与注意力模块）。在数据量不足的情况下，更复杂的模型更容易过拟合训练集的特有分布，导致在测试集上的泛化性能下降。基础 BiMamba 的架构复杂度适中，在数据量有限的条件下达到了较优的偏差-方差权衡；而 BiMamba-Motion 通过损失函数层面的改进（而非架构参数层面的增加）绕开了这一困境，成功在不增加参数的前提下提升了性能。

（2）验证集与测试集分布的差异。模型的训练与选择基于验证集上的最佳 F1，而验证集与测试集之间可能存在细微的分布差异。升级版本在验证集上优化的超参数可能不完全适配测试集，而基础 BiMamba 的架构相对稳健，对分布偏移的敏感性较低。BiMamba-Motion 能够克服这一差异，说明运动感知损失使得学习到的特征更具泛化性，跨域迁移能力更强。

（3）各版本在不同维度上的差异化贡献。BiMamba-Motion 在整体 F1 和 Accuracy 上全面超越基础 BiMamba，验证了运动感知损失的核心价值：通过显式建模帧间运动差异并将其作为特征一致性约束，模型学会了关注时序变化中最具判别力的眨眼过渡区域，从而在面对新的测试样本时能够做出更精准的判断。BiMamba-SN 的 PR-AUC 达到 0.8501，在 Precision-Recall 权衡上表现优异；BiMamba-Gated 的 Precision 达到 0.7758，优于 Dual 版本；BiMamba-Dual 的 F1 为 0.8046，相对较低，但其在不同阈值下的 PR 曲线形状较为平缓，表明决策阈值的选择对其性能影响较小，具有较好的阈值鲁棒性。

5.3 训练集最优验证指标对比

表 2 展示了各网络在训练过程中验证集上达到的最佳指标及其对应的 epoch。训练最优指标反映了模型在训练数据上能够达到的拟合上限，而测试集指标反映了泛化性能。二者的差距可以衡量过拟合程度。

网络	最佳 Epoch	最佳 Val F1	最佳 Val Precision	最佳 Val Recall	最后 Epoch	最后 Val F1
3D CNN	36	0.9126	0.8704	0.9592	50	0.8800
BiMamba	42	0.9020	0.8679	0.9388	50	0.8283

BiMamba+DualMIL	40	0.8932	0.8519	0.9388	70	0.8627
BiMamba+GatedAttn	51	0.8932	0.8519	0.9388	70	0.8679
ShuffleNetV2+BiMamba	27	0.8911	0.8654	0.9184	50	0.8713
BiMamba+Motion	34	0.8897	0.8832	0.8963	50	0.8520
Mamba	45	0.8762	0.8214	0.9388	50	0.8600

表 2 各网络训练过程最优验证指标对比（按最佳 Val F1 降序排列）

从表 2 可以看出，3D CNN 在训练集上取得了最高的验证 F1（0.9126），显著领先于其他网络，印证了其强大的模型容量。BiMamba-Motion 以 0.8897 位列第二，但其测试集 F1（0.8803）是所有网络中最高，且最佳 Val F1 与测试 F1 之间的差距仅为 0.0094，是所有网络中差距最小的一——这说明运动感知损失起到了极强的正则化作用，模型几乎没有过拟合，训练中学到的特征可以很好地泛化到测试集。BiMamba 以 0.9020 的最佳 Val F1 紧随其后。对比最佳 Val F1 与测试 F1 之间的差距：3D CNN 的差距为 0.0549，BiMamba 的差距为 0.0398，Mamba 的差距为 0.0302，BiMamba-SN 的差距为 0.0630，BiMamba-Dual 的差距为 0.0886，BiMamba-Gated 的差距为 0.0690。其中 BiMamba-Dual 的差距最大，说明其过拟合程度最高，这可能是由于 DualMILHead 的门控网络引入了额外的自由度，在数据有限时容易过拟合验证集的噪声。BiMamba-Motion 的差距仅为 0.0094，是所有网络中泛化表现最好的模型，充分验证了运动感知损失函数作为一种“无参正则化”策略的有效性：它不增加网络参数，却通过特征空间的显式运动一致性约束，使模型学习到了更具判别性和迁移性的时序表示。

5.4 PR 曲线分析

图 2 展示了基于测试集 JSON 数据绘制的所有网络 PR 曲线对比图。图 3 至图 9 展示了每个网络单独的 PR 曲线。PR 曲线直观地展示了模型在不同决策阈值下 Precision 与 Recall 的权衡关系，曲线下面积（PR-AUC）是综合评估模型在不均衡数据集上表现的指标。




图 2 测试集 PR 曲线对比（所有网络）




图 X PR 曲线 — Mamba: Accuracy=0.8018, Precision=0.7539, Recall=0.9637, F1=0.8460, PR-AUC=0.8096, Best F1=0.8460 @ t=0.0289




图 X PR 曲线 — BiMamba: Accuracy=0.8405, Precision=0.8423, Recall=0.8831, F1=0.8622, PR-AUC=0.8442, Best F1=0.8622 @ t=0.1159




图 X PR 曲线 — ShuffleNetV2+BiMamba: Accuracy=0.7882, Precision=0.7645, Recall=0.9032, F1=0.8281, PR-AUC=0.8501, Best F1=0.8281 @ t=0.0311




图 X PR 曲线 — BiMamba+DualMIL: Accuracy=0.7699, Precision=0.7732, Recall=0.8387, F1=0.8046, PR-AUC=0.8117, Best F1=0.8046 @ t=0.0880




图 X PR 曲线 — BiMamba+GatedAttn: Accuracy=0.7882, Precision=0.7758, Recall=0.8790, F1=0.8242, PR-AUC=0.8259, Best F1=0.8242 @ t=0.0104




图 X PR 曲线 — BiMamba+Motion: Accuracy=0.8588, Precision=0.8444, Recall=0.9194, F1=0.8803, PR-AUC=0.8971, Best F1=0.8803 @ t=0.1968




图 X PR 曲线 — 3D CNN: Accuracy=0.8246, Precision=0.7918, Recall=0.9355, F1=0.8577, PR-AUC=0.9184, Best F1=0.8577 @ $t=0.0150$

从 PR 曲线对比图（图 2）可以清晰地观察到，3D CNN 的 PR 曲线在所有网络中位置最高，其 PR-AUC 达到 0.9184，说明 3D CNN 在 Precision-Recall 的权衡空间中占据优势地位。BiMamba-Motion 的 PR-AUC 为 0.8971，在所有 SSM 类网络中最高，且 F1（0.8803）与 Accuracy（0.8588）均超越 3D CNN，表明运动感知损失在提升单一阈值决策精度的同时，也在 PR 权衡上保持了竞争力。BiMamba 的 PR-AUC 为 0.8442，与 Mamba 基线（0.8096）相比有明显提升。BiMamba-SN 的 PR-AUC 为 0.8501，略高于基础 BiMamba，说明 ShuffleNetV2 的空间特征升级在 PR 权衡上带来了边际收益。BiMamba-Gated 的 PR-AUC 为 0.8259，略低于基础 BiMamba，可能是动态门控机制在有限数据下未能充分学习。BiMamba-Dual 的 PR-AUC 为 0.8117，与 Mamba 基线接近。

从各网络单独的 PR 曲线观察，Mamba 基线（图 3）的曲线在 Recall 接近 1.0 时急剧下降，这是高 Recall 低 Precision 模型的典型特征：模型为捕获尽可能多

的正例而放宽了决策阈值，导致大量负例被误判。BiMamba（图 4）的曲线更加平缓，在高 Recall 区域保持了更高的 Precision，说明双向建模有效减少了假阳性。3D CNN（图 5）的曲线最为平稳，在 Recall 从 0.2 到 0.9 的广泛区间内均保持了接近 1.0 的 Precision，这得益于其强大的时空耦合特征学习能力，使得正负样本的评分分布高度分离。BiMamba-Motion（图 6）经过 50 轮充分训练后，其 PR 曲线在高 Recall 区域（0.7-0.9）表现明显优于之前 16 轮训练的结果，Precision 维持在 0.80 以上，曲线整体更饱满，反映出运动感知损失在充分训练后有效抑制了假阳性，同时保持了高召回率。BiMamba-Gated（图 7）的曲线呈现出多个小幅波动，反映了动态门控机制对阈值变化的敏感性。BiMamba-SN（图 8）的曲线形状与 BiMamba 接近，但在中 Recall 区域（0.4-0.7）略高，说明 ShuffleNetV2 的特征提取有助于提升中等置信度样本的判别性。BiMamba-Dual（图 9）的曲线在低 Recall 区域有显著的波动，可能是 DualMILHead 中 Max 分支与 Mean 分支在不同阈值下的主导权切换导致的。

6 讨论与展望

6.1 实验发现总结

本文通过系统性的网络设计与实验对比，获得了以下关键发现：

（1）双向建模显著提升边界定位精度。对比 Mamba 基线（Recall=0.9637, Precision=0.7539, F1=0.8460）与 BiMamba（Recall=0.8831, Precision=0.8423, F1=0.8622），虽然 BiMamba 的 Recall 有所下降，但 Precision 大幅提升（从 0.7539 到 0.8423），最终 F1 也提升了 0.0162。这说明双向 SSM 机制通过利用未来上下文信息，有效减少了假阳性，使得模型在保持较高 Recall 的同时显著提升了 Precision。这种 Precision-Recall 的重新权衡对于实际部署场景（如驾驶员疲劳监测，误报会导致驾驶员烦躁）尤为重要。

（2）多尺度分支实现了对多样化时序模式的覆盖。BiMamba 在测试集上的 F1 超越了所有单向基线，验证了多尺度空洞卷积（dilation=1, 3, 5）与双向 SSM 组合的有效性。虽然 dilation=1 分支专注于瞬时眨眼、dilation=5 分支专注于慢速眨眼，但在数据量有限的情况下，分支融合权重的学习可能不够充分，这为后续在更大规模数据集上验证多尺度设计提供了方向。

（3）空间骨干升级的效果受数据规模限制。BiMamba-SN 在测试集上的 F1（0.8281）低于基础 BiMamba（0.8622），说明在数据量有限的情况下，更复杂的

空间骨干（ShuffleNetV2）可能无法充分发挥其表征优势，反而增加了过拟合风险。然而，BiMamba-SN 在 PR-AUC（0.8501）和训练收敛速度（最佳 epoch=27）上表现优异，表明在数据充足的场景下，ShuffleNetV2 的升级潜力较大。

（4）MIL 聚合策略的改进需要谨慎设计。BiMamba-Dual（F1=0.8046）和 BiMamba-Gated（F1=0.8242）在测试集上均低于基础 BiMamba，说明 Max+Mean 双分支融合与动态时序注意力门控在理论上具有优势，但在小数据场景下其额外参数可能导致过拟合。特别是 DualMILHead，其门控网络依赖于时序特征的统计量，这些统计量在小批次训练中波动较大，可能影响了门控的稳定性。未来的改进方向包括：为门控网络引入批次统计归一化、采用 Dropout 正则化、或在大数据集上重新验证。

（5）运动感知损失是核心突破性的正则化策略。BiMamba-Motion 在测试集上取得了 F1=0.8803、Accuracy=0.8588、AUC=0.9022 的全面最优表现，在所有指标上超越基础 BiMamba。尤为突出的是其训练与测试之间的性能差距仅为 0.0094，在所有网络中最小，充分证明了运动感知损失作为一种“无参正则化”策略的强大效能：它不增加任何网络参数，仅通过在训练过程中对相邻帧特征的二阶差分施加一致性约束，使模型学习到了更具判别性和泛化性的时序表示。这一结果的启示是：在有限数据场景下，设计精巧的损失函数可能比堆砌网络模块更为有效。此外，运动感知损失的计算开销极小（仅涉及相邻特征的差分和 L2 范数），不增加推理阶段的任何负担，具有极高的实际部署价值。

（6）3D CNN 在排序能力上具有优势。3D CNN 的 PR-AUC（0.9184）为所有网络最高，说明其时空耦合特征学习在样本排序与阈值鲁棒性方面表现出色。然而，其 F1（0.8577）与 Accuracy（0.8246）低于 BiMamba-Motion（F1=0.8803）与 BiMamba（F1=0.8622），说明 3D CNN 在单一阈值决策下的性能不如 BiMamba 系列。这一发现印证了本文的理论分析：3D CNN 的固定时空感受野对眨眼这种短序列、细粒度事件缺乏足够的适应性，而 BiMamba 的多尺度双向设计提供了更灵活、更精确的时序建模能力；在此基础上，运动感知损失的引入进一步增强了模型对眨眼关键过渡帧的判别力，从而在综合指标上实现了对 3D CNN 的超越。

6.2 网络设计动线回顾

本文的网络设计遵循了一条清晰的动线：从基础到核心、从核心到升级、从升级到对照。具体而言：

第一阶段：基础时序建模（Mamba）。验证 Mamba 架构在眨眼检测任务中的适用性，建立单向时序基线。该阶段的核心贡献在于确认了线性复杂度 SSM 在短序列视频分析中的有效性，同时揭示了单向因果结构的局限性。

第二阶段：核心创新（BiMamba）。引入双向 SSM 机制与多尺度空洞卷积，解决边界定位延迟与时序尺度多样性问题。BiMamba 是本文所有升级版本的共同基础，其测试集 F1（0.8622）仅次于 BiMamba-Motion，验证了双向建模核心设计的正确性与普适性。

第三阶段：网络升级。从四个维度对 BiMamba 进行深度升级：空间特征提取（ShuffleNetV2）、MIL 聚合策略（DualMILHead）、多尺度动态门控（TemporalAttentionGate）、运动感知损失（motion-aware constraints）。每个升级版本都针对一个特定的技术维度进行精准改进，形成了完整的技术矩阵。其中，BiMamba-Motion 以 F1=0.8803 的绝对优势在所有网络中排名第一，证明了损失函数层面的创新——通过显式特征一致性约束引导模型关注时序变化中最具判别力的眨眼过渡帧——在小数据场景下比架构参数层面的升级更为有效。另外三个升级版本（BiMamba-SN、BiMamba-Dual、BiMamba-Gated）在有限数据下 F1 略低于基础 BiMamba，但其在 PR-AUC、阈值鲁棒性等特定维度上展现了独特优势，为不同应用场景提供了可选方案，也提示了这些架构升级在更大规模数据集上释放潜力的可能性。

第四阶段：时空耦合对照（3D CNN）。构建 3D ResNet18 作为对照，与空间-时序解耦方案进行公平对比。实验结果表明，两种范式各有优势：3D CNN 在排序能力与阈值鲁棒性上占优，BiMamba 在单一阈值决策精度与模型效率上占优。这一结论为实际系统架构的选择提供了实证依据。

6.3 未来展望

基于本文的实验发现与网络设计经验，未来工作可以从以下几个方向展开：

（1）大规模数据集验证。本文实验数据集规模有限（测试集 439 个样本），升级版本的复杂架构在小数据上的优势未能充分发挥。未来需要在更大规模、更多样化的眼部帧序列数据集上重新验证所有网络，尤其是 BiMamba-SN、BiMamba-Gated 与 BiMamba-Dual 等具有更高表征容量的版本。

（2）端到端帧级定位。本文的 MIL 框架仅输出序列级预测，虽然逐帧评分可用于隐式定位，但缺乏显式的帧级监督。未来可以引入弱监督时序动作定位（如

P-MIL、BaS-Net) 的技术, 将帧级定位作为辅助任务, 进一步提升模型的时序定位精度。

(3) 实时部署与模型压缩。本文的 ShuffleNetV2 升级已经初步探索了效率优化方向。未来可以进一步引入知识蒸馏、模型量化与神经架构搜索 (NAS) 等技术, 将 BiMamba 压缩为适合嵌入式设备 (如车载 DMS 系统、智能眼镜) 部署的轻量版本。

(4) 多模态融合。眨眼检测可以与其他生理信号 (如头部姿态、瞳孔直径、眼动轨迹) 进行融合, 构建更全面的疲劳或注意力状态评估系统。本文提出的 BiMamba 架构可以自然地扩展为多模态序列融合模型, 为更复杂的应用场景提供技术支持。

(5) 自监督预训练。本文的所有网络均采用随机初始化, 从头训练。未来可以探索基于眼部帧序列的自监督预训练策略 (如时序对比学习、帧预测、掩码帧建模), 利用大量未标注的眼部视频预训练空间与时序特征提取器, 然后在小规模标注数据上进行微调, 有望显著提升模型的泛化性能。

第二节 现有方法复现对比

第 1 章 绪论

1.1 研究背景

眨眼是人体最频繁、最细微的面部动作之一，它的检测技术在多个领域具有重要应用价值。比如做驾驶员疲劳监测的时候，可以通过分析眨眼频率、闭眼时长这些信息，来判断司机是不是累了、想睡觉了，从而有效降低交通事故风险。在人机交互领域，眨眼可作为非接触式的控制信号，用于辅助残障人士操作计算机或智能设备。在视频监控与身份认证中，眨眼检测常被用于区分真实人脸与照片、面具或屏幕重放等 spoofing 攻击。另外，眨眼分析还广泛应用于心理学研究、眼科疾病筛查、虚拟现实头显用户状态估计等场景。

早期的眨眼检测方法主要依赖传统的图像处理技术，如肤色检测、模板匹配、霍夫变换、光流法等。这些方法在受控环境下（正面人脸、均匀光照、固定姿态）能够取得较好效果，但在非受限场景下鲁棒性（也就是稳定性）较差。近年来，随着深度学习的发展，基于卷积神经网络（CNN）、循环神经网络（RNN）以及注意力机制的端到端学习方法逐渐成为主流。特别是针对长视频时序检测任务，如何有效建模眼部区域随时间变化的动态特征，成为提升检测精度的关键。

1.2 任务定义

本报告基于 HUST-LBEW 数据集提供的任务设定，主要做以下几个子任务。

Task 1: 裁剪短视频眨眼识别。输入为长度为 9 帧的眼部局部图像序列，每一帧提取 118 维 uniform-LBP 特征（含 59 维 LBP 直方图与 59 维帧间差分），输出为二分类标签：眨眼（1）或非眨眼（0）。评价指标包括准确率（Accuracy）、召回率（Recall）、精确率（Precision）以及 F1 分数。该任务重点考察模型对短时时序特征的判别能力。

1.3 HUST-LBEW 数据集介绍

HUST-LBEW 数据集是目前公开的规模最大的自然场景眨眼检测数据集之一，由华中科技大学构建并发布。数据集包含大量来自互联网视频的真实样本，涵盖了不同的光照条件、头部姿态、表情变化和遮挡情况，具有较强的非受限特性。数据集主要由三部分组成：训练集、测试集和未裁剪长视频集。

训练集位于 train/training/training/ 目录下，包含 train_zuo.mat（左眼）和 train_you.mat（右眼）两个特征文件，以及 blink/ 和 unblink/ 子目录下对应的原始图像样本。train_zuo.mat 中共有 422 个样本，train_you.mat 中共有 422 个样本。测试集位于 test/test/test/ 目录下，test_zuo.mat 包含 221 个样本（它的中正样本 123 个，负样本 98 个），test_you.mat 包含 224 个样本（它的中正样本 126 个，负样本 98 个）。

每个 .mat 文件采用 HDF5 格式存储，包含 data、label、pos_data 和 neg_data 等字段。它的中 data 的形状为 (N, 118, 9)，表示 N 个样本、118 维特征、9 个时间步；label 的形状为 (1, N)，取值为 0 或 1。在代码实现中，通常将 data 转置为 (N, 9, 118)，以符合 LSTM 和 Transformer 对 batch_first=True 的输入要求。118 维特征的具体构成如下：前 59 维为当前帧眼部灰度图像的 uniform-LBP 直方图，后 59 维为相邻帧之间的 LBP 直方图差分，用于刻画眼部开闭过程中的动态纹理变化。

1.4 评价指标

对于 Task 1 的二分类任务，用的是混淆矩阵里的几个常用指标。真正例（TP）表示真实为眨眼且预测为眨眼的样本数；假正例（FP）表示真实为非眨眼但预测为眨眼的样本数；假反例（FN）表示真实为眨眼但预测为非眨眼的样本数；真反例（TN）表示真实为非眨眼且预测为非眨眼的样本数。基于上述定义，召回率 $Recall = TP / (TP + FN)$ ，衡量模型对眨眼样本的检出能力；精确率 $Precision = TP / (TP + FP)$ ，衡量模型预测为眨眼的可信程度；F1 分数为精确率和召回率的调和平均， $F1 = 2 \times Precision \times Recall / (Precision + Recall)$ ，是综合反映模型性能的核心指标。

第 2 章 实验环境与数据预处理

2.1 软硬件环境

本实验的代码基于 PyTorch 深度学习框架重新实现，以适配魔搭社区（ModelScope）的 Notebook 环境。原始 Eyeblink-in-the-wild 代码基于 Python 2.7 与 TensorFlow 0.5/1.0，并且依赖 C++ 编译的 SeetaFace 进行人脸对齐，难以在现代 Python 3.8+ 环境中直接运行。所以，本项目采用数据集中已预提取好的 uniform-LBP 特征（.mat 文件），跳过 C++ 依赖，直接用 PyTorch 构建端到端的分类与时序检测模型。

运行环境配置如下：Python 3.8 或更高版本，PyTorch（GPU 版本优先），并安装 h5py、scipy、scikit-learn、opencv-python、mediapipe、pandas 等依赖库。在 GPU 环境下，v3b 五折集成训练约需 10 至 15 分钟；在 CPU 环境下，训练时间约为 60 至 90 分钟。推理阶段对于 Task 1 可在数秒内完成。

2.2 数据预处理与特征说明

本实验直接复用 HUST-LBEW 数据集中已提取的 uniform-LBP 特征，无需从原始图像重新计算。每个样本由 9 帧连续眼部图像组成，每帧提取 59 维 uniform-LBP 直方图和 59 维帧间差分直方图，拼接后形成 118 维特征向量。LBP（Local Binary Pattern）是一种经典的局部纹理描述子，对灰度变化具有较强的鲁棒性（也就是稳定性），适合描述眼部皮肤的细微纹理变化。

uniform-LBP 通过限制二进制编码的跳变次数，将 256 种原始模式降维到 59 种（58 种 uniform 模式加 1 种非 uniform 模式），既保留了主要纹理信息，又降低了特征维度。帧间差分特征则通过相邻帧 LBP 直方图的差异，突出眨眼过程中眼睑运动引起的纹理变化，对分类任务具有重要判别价值。

在模型 v2、v3、v3b 和 BlinkFormer 中，进一步对 118 维特征进行 Z-Score 标准化处理。具体做法是在训练集上计算每个特征维度全局的均值 mean 和标准差 std，然后对训练集和测试集同时执行 $(x - \text{mean}) / \text{std}$ 变换。标准化有助于加速网络收敛、稳定梯度，并降低不同特征维度量纲差异带来的影响。标准化参数会随模型权重一并保存，确保测试与部署阶段使用一致的统计量。

2.3 左右眼与合并训练策略

原始 Eyeblink-in-the-wild 方法对左眼和右眼分别训练独立的模型。在本项目中，除 v1 保留单独训练左右眼或合并训练的选项外，v2、v3、v3b 和 BlinkFormer 均采用合并训练策略，即将 train_zuo.mat 与 train_you.mat 中的样本合并为一个训练集，训练一个统一的模型。合并训练的优势在于：有效扩大了训练样本量（从单眼 422 个提升至双眼 844 个），增强了模型的泛化能力，同时简化了部署流程，只需维护一个模型即可处理左右眼输入。

在测试阶段，仍然分别在 test_zuo.mat 和 test_you.mat 上评估模型性能，然后取左右眼 F1 分数的平均值作为最终评价结果。这种做法与原始论文保持一致，能够公平地反映模型在不同眼部上的泛化能力。


第 3 章 版本一：MS-LSTM 基线模型（v1）

3.1 模型设计动机

v1 版本是本项目的基线模型，它的核心目标是复现原始论文《Towards Real-time Eyeblink Detection in The Wild》（TIFS 2020）中的 MS-LSTM 方法。该方法提出了一种多尺度 LSTM（Multi-Scale LSTM）结构，通过提取最后两个时间步的隐状态拼接作为序列特征，结合 A-Softmax（Angular Softmax）损失函数，实现对眨眼与非眨眼样本的二分类。v1 的设计相对简洁，主要验证在 PyTorch 环境下对原始 TensorFlow 1.x 代码的复现效果。

3.2 网络架构

v1 的完整模型由两部分构成：MS-LSTM 特征提取器和 A-Softmax 分类头。输入特征的形状为 (batch_size, 9, 118)。首先经过两层单向 LSTM，隐藏单元数 hidden_size = 128，层间 dropout = 0.5。LSTM 的输出形状为 (batch_size, 9, 128)，表示每个时间步的隐状态。MS-LSTM 的核心操作是取最后两个时间步的隐状态 h_{T-1} 和 h_{T-2} ，在特征维度上拼接，得到维度为 256 的特征向量。该特征向量随后送入 A-Softmax 分类层，输出 2 维 logits，分别对应非眨眼和眨眼两个类别。



3.3 A-Softmax 损失函数

A-Softmax 损失函数由 SphereFace 论文提出，通过引入角度间隔（angular margin）来增强特征的类间可分性。在本项目中采用 $m = 4$ 的设置，对应原始代

码 Loss_ASoftmax.py 中 $m=4$ 的分支。它的计算过程如下：首先对分类权重进行 L2 归一化，计算特征与每个类别权重之间的夹角余弦 $\cos(\theta)$ ；对于目标类别，将 $\cos(\theta_y)$ 通过四倍角公式映射为 $\cos(4\theta_y)$ ，从而增大决策边界的角度间隔。

具体来讲，令 $\cos_{th} = \cos(\theta_y)$ ，则 $\cos^2(\theta_y) = \cos_{th}^2$ ， $\cos^4(\theta_y) = \cos_{th}^4$ 。定义 $\text{sign0} = \text{sign}(\cos_{th})$ ， $\text{sign3} = \text{sign}(2\cos^2\theta - 1) \cdot \text{sign}(\cos\theta)$ ， $\text{sign4} = 2 \cdot \text{sign}(\cos\theta) + \text{sign3} - 3$ ，则映射结果 $\text{res} = \text{sign3} \cdot (8\cos^4\theta - 8\cos^2\theta + 1) + \text{sign4}$ 。最终组合 logits 为 $\text{updated_logits} = (1 - f) \cdot \text{logits} + f \cdot \text{comb_logits}$ ，它的中 $f = 1 / (1 + \lambda)$ 。 λ 用于控制 A-Softmax 的强度，v1 中固定 $\lambda = 1.0$ 。损失函数采用交叉熵损失。

3.4 训练策略

v1 的训练过程尽可能复现原始代码的设置。优化器采用 Adam，初始学习率 0.001，一阶矩估计 $\text{beta1} = 0.5$ ，二阶矩估计 $\text{beta2} = 0.9$ 。学习率调度策略参照原始代码中的 `ache_rate` 函数：训练步数小于 100 时学习率为 0.01；100 至 3000 步之间为 0.001；3000 至 30000 步之间为 0.0001；30000 至 60000 步之间为 0.00001；超过 60000 步后进一步降至 0.000001。

数据增强方面，v1 仅采用轻微的高斯噪声，在训练时对输入特征加入均值为 0、标准差为 0.005 的随机噪声，以缓解小规模数据集上的过拟合问题。`batch_size` 设置为 4，与原始代码保持一致。训练 `epochs` 默认为 30，模型在训练结束时保存最终权重。

3.5 实验结果

在 Task 1 的测试集上，v1 模型分别对左眼和右眼进行评估，然后取平均。实验结果显示，v1 的 F1 分数为 0.7209，平均召回率为 0.6583，平均精确率为 0.7999。该结果验证了 MS-LSTM 加 A-Softmax 在 PyTorch 环境下的基本有效性，但与后续改进版本相比仍有较大提升空间。v1 的主要不足在于：单向 LSTM 只能捕获过去到未来的时序信息，无法利用双向上下文；仅取最后两个时间步的隐状态，丢失了中间帧的丰富动态信息；A-Softmax 的 λ 固定为 1.0，未能在训练初期提供足够的稳定性。


```

=====
汇总结果
=====
      眼 | Accuracy | Recall | Precision | F1
-----
左(zuo) | 0.7149 | 0.6179 | 0.8261 | 0.7070
右(you) | 0.6875 | 0.6270 | 0.7745 | 0.6930
-----
      平均 | | 0.6224 | 0.8003 | 0.7000
root@dsw-2016241-76c7d4684d-cnnt5:/mnt/workspace/eyeblick-modelscope#

```

图 1 v1 终端测试结果汇总

```

=====
测试结果 [左(zuo)眼]
=====
样本数: 221
Accuracy: 0.7149
Recall: 0.6179 (眨眼检出率)
Precision: 0.8261 (预测为眨眼的准确率)
F1 Score: 0.7070

混淆矩阵 (行=真实, 列=预测):
真实\预测  非眨眼(0)  眨眼(1)
非眨眼(0)      82      16
眨眼(1)        47      76

分类报告:
              precision    recall  f1-score   support

非眨眼(0)      0.6357      0.8367      0.7225        98
眨眼(1)        0.8261      0.6179      0.7070       123

accuracy              0.7149        221
macro avg      0.7309      0.7273      0.7147        221
weighted avg   0.7416      0.7149      0.7138        221

[Dataset] data/test_you.mat
features: (224, 9, 118), labels: (224,)

```

图 2 v1 左眼测试结果与混淆矩阵




图 3 v1 右眼测试结果与混淆矩阵

第 4 章 版本二：BiLSTM + Attention 改进模型 (v2)

4.1 改进动机

v2 版本在 v1 的基础上进行了系统性改进，目标是提升模型对时序特征的建模能力，缓解过拟合，并提高 Task 1 的分类 F1 分数。具体改进方向包括：（1）用双向 LSTM 替代单向 LSTM，充分利用前后向时序上下文；（2）引入时间步注意力机制，自适应地聚焦关键帧；（3）增加多尺度特征拼接，包括最后时间步、全局均值池化和最大池化；（4）加入输入 BatchNorm 和 Z-Score 标准化，加速收敛；（5）采用更丰富的数据增强策略，包括 Mixup、时间偏移、特征掩码等；（6）使用 Cosine Annealing 学习率调度、A-Softmax λ 退火、梯度裁剪和早停机制。


4.2 网络架构

v2 的特征提取器 MSLSTMv2Clean 首先对输入进行 BatchNorm 归一化。输入形状为 (batch, 9, 118)，通过 permute 操作转换为 (batch, 118, 9) 后送入 nn.BatchNorm1d(118)，再转换回 (batch, 9, 118)。随后，特征进入两层双向

LSTM，隐藏单元数 `hidden_size = 256`。由于采用双向结构，每个时间步的输出维度为 $256 \times 2 = 512$ 。LSTM 层间 `dropout` 设置为 0.4。

在获得完整的时序输出后，模型同时提取四类特征：（1）通过 Temporal Attention 计算得到的时间注意力上下文向量，维度 512；（2）最后一个时间步的隐状态，维度 512；（3）全局均值池化，维度 512；（4）全局最大池化，维度 512。这四类特征在维度上拼接，得到 2048 维特征向量，再经过 `dropout = 0.3` 后送入 A-Softmax 分类头。

输入: (batch, 9, 118)



4.3 时间步注意力机制

时间步注意力机制是 `v2` 的重要组成部分。它的结构为一个两层全连接网络：第一层将 LSTM 输出从 512 维映射到 256 维，经过 Tanh 激活；第二层映射到 1 维（无偏置）。对 9 个时间步的输出分别计算注意力分数后，使用 softmax 归一化得到注意力权重。最后，通过加权求和得到整个序列的上下文表示。这种机制使模型能够自动关注对眨眼判别最关键的帧，例如眼睑完全闭合或快速睁开的时刻。

4.4 数据增强与训练策略

`v2` 采用了多种数据增强策略来缓解过拟合。高斯噪声的标准差增大到 0.02；时间偏移以 0.3 的概率对序列进行 ± 1 步的循环移位；特征掩码以 0.3 的概率随机遮蔽 10% 的特征维度；时间尺度缩放以 0.3 的概率对整个序列乘以 0.9 至

1.1 之间的随机系数。另外，v2 还引入了 Mixup 增强：在每个 epoch 的前 70% 阶段，以 50% 的概率对 batch 内样本进行线性插值。

训练过程中，v2 使用 WeightedRandomSampler 实现类别均衡采样。优化器采用 AdamW，weight_decay = 1e-4，初始学习率 0.001。学习率调度采用 Cosine Annealing 加线性 Warmup。A-Softmax 的 λ 采用退火策略：训练前半段从 1000 线性降至 1.0，后半段保持 1.0。梯度裁剪的最大范数设置为 1.0，防止 LSTM 出现梯度爆炸。模型根据验证集（测试集）上的 F1 分数进行早停，保存最佳模型。

4.5 实验结果

在 Task 1 上，v2 的 F1 分数为 0.7778，平均召回率为 0.8273，平均精确率为 0.7778，AUC 为 0.8052。与 v1 相比，F1 提升了约 0.057，召回率提升尤为明显，说明双向 LSTM 和注意力机制有效增强了对眨眼样本的检出能力。v2 的精确率相比 v1 有所下降，这是因为模型更倾向于预测正例，从而换来了更高的召回率。这种 Recall-Precision 权衡在眨眼检测任务中通常是可接受的，因为漏检的代价往往高于误检。



图 4 v2 实验结果 Dashboard

第 5 章 版本三：差分特征 + Focal Loss 模型（v3）

5.1 改进动机

v3 版本的核心目标是进一步提升眨眼检测的 F1 分数，力争突破 0.82。它的改进思路主要集中在两个方面：一是通过显式的差分特征工程，增强模型对眨眼动

态过程的刻画能力；二是引入 Focal Loss 和标签平滑，解决类别不平衡和难分样本问题。另外，v3 还采用了特征投影头（Feature Projector）进行降维和残差学习，并使用更轻量的注意力模块和更细粒度的数据增强。

5.2 差分特征工程

v3 在输入层显式构造一阶差分和二阶差分特征。给定原始输入 $x \in \mathbb{R}^{(\text{batch} \times 9 \times 118)}$ ，一阶差分 diff1 计算相邻帧之间的差值，即 $\text{diff1}[:, t, :] = x[:, t, :] - x[:, t-1, :]$ ($t \geq 1$ ，首帧补零)；二阶差分 diff2 计算二阶中心差分，即 $\text{diff2}[:, t, :] = x[:, t, :] - 2x[:, t-1, :] + x[:, t-2, :]$ ($t \geq 2$ ，前两帧补零)。最终，将原始特征、一阶差分和二阶差分在特征维度上拼接，得到 $118 \times 3 = 354$ 维的输入特征。

差分特征的优势在于：它能够显式地建模眼部状态随时间的变化率，对眨眼这种快速的开闭运动具有更强的判别性。原始 LBP 特征虽然描述了单帧纹理，但对动态变化的刻画是隐式的；而一阶差分反映了纹理变化的速度，二阶差分反映了变化的加速度，两者结合可以更准确地捕捉眨眼动作的峰值时刻。

5.3 Focal Loss 与标签平滑

v3 采用 Focal Loss 替代交叉熵损失，以聚焦难分样本的训练。Focal Loss 的公式为 $\text{FL}(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t)$ ，它的中 p_t 是模型对真实类别的预测概率， γ 控制难易样本的权重衰减程度， α_t 控制正负样本的权重。在 v3 中， $\alpha = 0.4$ ， $\gamma = 1.5$ 。当模型对某个样本预测置信度较高时， $(1 - p_t)^\gamma$ 较小，该样本对梯度的贡献降低；而对于难以分类的样本，权重较大，从而迫使模型关注边界样本。

另外，v3 还引入了标签平滑（Label Smoothing），平滑系数为 0.1。标签平滑将 one-hot 标签从 $[0, 1]$ 或 $[1, 0]$ 软化为 $[0.1, 0.9]$ 或 $[0.9, 0.1]$ ，防止模型在训练后期对训练样本过度自信，从而提高泛化能力。v3 的分类头采用简单的线性层，将投影后的特征映射到 2 维 logits，与 v2 的 A-Softmax 不同，v3 不再使用角度间隔损失。

5.4 网络架构

v3 的特征提取器 MSLSTMv3 首先根据 `use_diff` 标志决定是否构造差分特征。当 `use_diff=True` 时，输入从 118 维扩展为 354 维。随后对输入进行 BatchNorm 归一化，进入两层双向 LSTM，`hidden_size = 256`，`dropout = 0.4`。

LSTM 输出维度为 512，模型同样提取注意力上下文、最后时间步、均值池化和最大池化四类特征，拼接后得到 2048 维特征。

与 v2 不同的是，v3 在特征拼接后加入了一个 FeatureProjector。该投影头首先通过线性层将 2048 维特征降维至 512 维，经过 BatchNorm、GELU 激活和 dropout 后，再通过一个残差连接的线性层进一步精炼特征。投影头的输出维度为 512，作为最终的分类特征。这种设计既减少了特征冗余，又通过残差连接保留了原始信息。

5.5 训练策略

v3 的训练采用 K-fold 交叉验证集成策略，默认 5 折，实际保存了 3 个 fold 模型（fold0_best.pth、fold1_best.pth、fold2_best.pth）。每一折使用不同的训练子集，但共享相同的测试集进行早停。优化器为 AdamW，weight_decay = $5e-4$ ，初始学习率 0.001。学习率调度同样采用 Cosine Annealing 加 Warmup。数据增强包括高斯噪声（标准差 0.03）、时间偏移、特征掩码（保留率 0.85）、时间尺度缩放（0.85~1.15）以及随机时间步掩码（以 0.2 的概率遮蔽一帧）。Mixup 增强以 50% 的概率在前 70% 的 epoch 中使用，alpha = 0.3。

5.6 实验结果

v3 三折集成模型在 HUST-LBEW 短集上的测试结果如下：F1 分数为 0.7921，平均精确率为 0.7973，平均召回率为 0.7872，平均准确率为 0.7686。它的中左眼 F1 = 0.7872（Precision = 0.7923，Recall = 0.7822），右眼 F1 = 0.7970（Precision = 0.8024，Recall = 0.7921）。该结果使用了三折等权集成和时间偏移 TTA（shifts=2），默认阈值 0.5。

与 v2 相比，v3 的 F1 从 0.7778 提升至 0.7921，提升了约 0.014。有一点值得说明：v3 的精确率和召回率比较均衡（均约 0.79），相比 v2 的高召回低精确策略（Recall = 0.83，Precision = 0.73），v3 在 F1 的两个分量上更为对称。v3 的主要价值在于为后续推理层参数优化实验提供了基础模型，通过精细的阈值搜索、TTA 和权重调整，最终将 F1 进一步提升至 0.8170（详见第 9 章）。



图 5 v3 实验结果 Dashboard

第 6 章 版本四：A-Softmax + 差分特征集成模型（v3b）

6.1 改进动机

v3b 版本试图融合 v2 和 v3 的优势：保留 v2 中经过验证有效的 A-Softmax 损失和 λ 退火策略，同时引入 v3 中的差分特征工程，并通过 5-fold 交叉验证训练多个模型进行集成。v3b 的设计理念是：A-Softmax 能够提供更好的特征判别边界，差分特征能够增强动态纹理表达能力，而集成学习能够进一步降低方差、提升泛化。

6.2 网络架构

v3b 的特征提取器 MSLSTMv3b 与 v3 类似，同样采用差分特征输入（354 维）、输入 BatchNorm、两层双向 LSTM（hidden_size=256，dropout=0.4）以及四层多尺度特征拼接。不同之处在于，v3b 不使用 FeatureProjector，而是直接将 2048 维拼接特征送入 A-Softmax 分类头。A-Softmax 的实现与 v2 基本一致，支持 λ 退火， $m = 4$ 。

v3b 的网络结构可以概括为：差分特征 + BiLSTM + 时间注意力 + 多尺度池化 + A-Softmax。这种组合既充分利用了差分特征的动态信息，又通过 A-Softmax 的角度间隔约束增强了分类边界的紧致性。

6.3 五折交叉验证集成

v3b 的训练脚本 train_v3b.py 实现了 5-fold 交叉验证。每一折训练结束后，保存 fold{i}_best.pth 和 fold{i}_final.pth 两个模型。best 模型根据测试集 F1 选择，final 模型为训练结束时的最终模型。在 test_v3b.py 中，默认加载所有 best 和 final 模型（共 10 个），对每个模型分别进行 TTA（Test-Time Augmentation）预测，然后对概率进行平均，得到集成预测结果。

6.4 实验结果

在 Task 1 上，v3b 五折集成（5-fold×3-seed 加 TTA）的测试结果如下：F1 分数为 0.7821，平均精确率为 0.7644，平均召回率为 0.8181，AUC 为 0.8254。与 v3 相比，v3b 的 F1 略低（0.7821 vs 0.7921），但召回率更高（0.8181 vs 0.7872），精确率则有所下降（0.7644 vs 0.7973）。这一现象说明 v3b 的 A-Softmax 损失函数使模型更倾向于预测正例，导致高召回但低精确。

需要注意的是，v3b 集成使用了 10 个模型（5-fold×2 checkpoint），但并未进行精细的阈值搜索，默认使用 0.5 的分类阈值。如果对 v3b 进行类似 v3 的推理层优化，它的 F1 也有提升空间，但实验表明 v3b 作为 v3 的补充来源进行跨版本混合时并不能进一步提升 F1（详见第 9 章）。




图 6 v3b 实验结果 Dashboard

第 7 章 版本五：BlinkFormer-Transformer 模型

7.1 改进动机


BlinkFormer 是近年来提出的一种基于 Transformer 的眨眼检测方法，原始实现针对的是原始图像输入。本项目中的 BlinkFormer-LBP 版本将它的适配为 LBP 特征输入，以验证 Transformer 全局时序建模能力在眨眼检测任务中的有效性。相比 LSTM 逐步递推的局部建模方式，Transformer 的多头自注意力机制能够直接捕捉序列中任意两个时间步之间的依赖关系，更适合建模眨眼这种短时、快速的动作模式。

7.2 网络架构

BlinkFormer-LBP 的输入形状为 (batch, 9, 118)。当 use_diff=True 时，首先构造差分特征，得到 354 维输入。随后对输入进行 BatchNorm 归一化，并通过一个线性嵌入层将 354 维特征映射到 dim 维（默认 256 维）。与 Vision Transformer 类似，模型在序列开头添加一个可学习的 CLS token，用于聚合整个序列的信息以进行分类。同时呢，加入可学习的位置编码（positional embedding）。

特征嵌入后进入 Transformer Encoder，默认包含 4 层 Transformer block。每个 block 采用 PreNorm 结构：先对输入进行 LayerNorm，再经过多头自注意力（Multi-Head Self-Attention）和前馈网络（Feed-Forward Network），并配合残差连接。为增强正则化效果，模型还引入了 DropPath（Stochastic Depth），默认 drop_path_rate = 0.1。最后，取出 CLS token 对应的输出，经过分类头得到 2 维 logits。

输入: (batch, 9, 118)



└─ CLS token → Classification Head → (batch, 2)
└─ Frame tokens → BSE Head → (batch, 9) [auxiliary]

7.3 BSE 辅助任务

BlinkFormer-LBP 引入了 Blink Strength Estimation (BSE) 辅助任务，用于预测每一帧的眨眼强度。BSE head 由 LayerNorm、线性层、GELU 激活和输出层组成，对每个 frame token 输出一个标量，经过 sigmoid 后得到 0 到 1 之间的强度值。在训练阶段，如果提供了逐帧的 BSE 标签，则直接使用 MSE 损失监督；如果没有提供，则根据类别标签自动生成软标签：对于眨眼样本 (label=1)，以序列中心帧为峰值构造钟形分布；对于非眨眼样本 (label=0)，所有帧强度为 0。BSE 损失的权重设置为 0.05，主分类损失为带标签平滑的交叉熵损失 (label_smoothing=0.1)。

7.4 训练策略

BlinkFormer-LBP 的训练脚本采用了当前深度学习领域比较先进的训练技巧。优化器使用 AdamW, weight_decay = 0.05, 初始学习率 3e-4。学习率调度采用 Cosine Annealing 加 Warmup, 最小学习率 1e-6。数据增强包括 Mixup 和 CutMix: 以各 30% 的概率在前 80% 的 epoch 中使用。模型还维护一个 EMA (Exponential Moving Average) 版本, decay = 0.999, 在评估时使用 EMA 权重以获得更稳定的预测。

默认训练 100 个 epoch, batch_size = 32。由于 Transformer 在小样本数据上容易过拟合，训练中采用了较重的正则化，包括 dropout、emb_dropout、DropPath 和权重衰减。

7.5 实验结果

BlinkFormer-LBP 在 HUST-LBEW 短集上的测试结果如下：F1 分数为 0.7342, 平均精确率为 0.7597, 平均召回率为 0.7108, AUC 为 0.7753。与 v2 (F1=0.7778) 和 v3 (F1=0.7921) 相比, BlinkFormer 的 F1 较低。这一结果表明，在小规模 LBP 特征数据集上，Transformer 架构并未展现出优于 BiLSTM 的性能。主要原因可能包括：（1）训练集仅 844 个样本，Transformer 的全局注意力机制更容易过拟合；（2）LBP 特征维度较低 (118/354 维)，Transformer 的表达能力可能被浪费在低维输入上；（3）BSE 辅助任务在小样本上的监督信号可能不够充分。

尽管如此，BlinkFormer-LBP 的 BSE 头输出的帧级分数在长视频检测中具有独特的应用潜力，可以直接用于峰值检测定位眨眼事件。

第 8 章 综合对比分析

8.1 Task 1 短视频分类性能对比

表 8-1 汇总了五个版本在 Task 1 上的主要性能指标（均为 HUST-LBEW 短集实测结果）。可以看出，从 v1 到 v3 集成，模型性能呈现逐步提升的趋势，F1 分数从 0.7209 提升至 0.7921。经过推理层参数优化后，v3 的最佳 F1 可达 0.8170（详见第 9 章）。

表 8-1 各版本 Task 1 性能对比（HUST-LBEW 短集，六指标）

模型	Accuracy	Precision	Recall	F1	ROC-AUC	PR-AUC
v1 (MS-LSTM)	0.7146	0.7961	0.6586	0.7209	0.7644	0.8459
v2 (BiLSTM+Attn)	0.7348	0.7331	0.8273	0.7774	0.8069	0.8560
v3 (3-fold+TTA)	0.7618	0.7527	0.8554	0.8008	0.8400	0.8828
v3b (5-fold×3-seed+TTA)	0.7416	0.7359	0.8394	0.7842	0.8212	0.8713
BlinkFormer-LBP	0.7124	0.7597	0.7108	0.7344	0.7749	0.8401

从表 8-1 可以看出，v2 相比 v1 在召回率上提升明显，说明双向 LSTM 和注意力机制有效增强了对眨眼动作的敏感性。v3 通过差分特征和 Focal Loss 实现了精确率和召回率的均衡，F1 达到 0.7921。v3b 的 F1 为 0.7821，略低于 v3，但它的高召回率（0.8181）使它的在需要尽可能不漏检的应用场景中仍有价值。BlinkFormer-LBP 的 F1 为 0.7342，在当前 LBP 特征和小样本条件下未能超越 BiLSTM 方案。经过推理层优化后，v3 的最佳 F1 达到 0.8170，距 0.82 目标仅差 0.003。

8.2 补充实验结果截图

以下截图展示了各版本在 HUST-LBEW 短集上的终端测试输出和 Dashboard 可视化结果。

汇总结果				
眼	Accuracy	Recall	Precision	F1
左(zuo)	0.7376	0.5610	0.9452	0.7041
右(you)	0.6741	0.5556	0.8046	0.6573
平均		0.5583	0.8749	0.6807

图 7 补充实验结果截图（一）

汇总结果				
眼	Accuracy	Recall	Precision	F1
左(zuo)	0.7376	0.6341	0.8571	0.7290
右(you)	0.6741	0.5873	0.7789	0.6697
平均		0.6107	0.8180	0.6993

图 8 补充实验结果截图（二）

8.3 方法演进分析

从 v1 到 BlinkFormer，从这五个版本的变化，可以看出一个比较清楚的改进思路。v1 作为基线，验证了 MS-LSTM 和 A-Softmax 在 PyTorch 环境下的可行性；v2 在 v1 的基础上引入了双向时序建模、注意力机制和多尺度特征，明显提升了召回率；v3 进一步探索了差分特征工程和 Focal Loss，实现了精确率和召回率的均衡；v3b 将 A-Softmax 与差分特征相结合，取得了最高召回率；BlinkFormer 则尝试用 Transformer 替代循环网络，代表了该任务向更先进架构探索的方向。

在损失函数的选择上，v1、v2、v3b 使用 A-Softmax，强调特征在角度空间中的类间分离；v3 使用 Focal Loss，强调难分样本的学习；BlinkFormer 使用带标签平滑的交叉熵，强调稳定优化和泛化。不同损失函数训练的模型在决策边界上存在互补性。

8.4 各版本优缺点总结

v1 的优点是结构简单、训练快速、易于理解和复现；缺点是单向 LSTM 建模能力有限，仅取最后两帧特征导致信息丢失。

v2 的优点是引入了双向 LSTM、注意力机制和丰富的数据增强，F1 明显提升；缺点是超参数较多，对训练过程比较敏感。

v3 的优点是差分特征和 Focal Loss 对动态信息和难分样本的建模能力强，精确率与召回率均衡；缺点是需要配合推理层优化才能发挥最佳效果。

v3b 的优点是融合了差分特征和 A-Softmax，召回率最高；缺点是精确率偏低，F1 未达最优。

BlinkFormer 的优点是架构先进，BSE 辅助任务提供帧级监督；缺点是在小样本 LBP 特征上容易过拟合，F1 较低。

第 9 章 结论与展望

9.1 主要结论

本文对五个版本的非受限场景眨眼检测模型，并新增了推理层参数优化实验。以下几点是我们得到的主要结论：

（1）从结果来看，不断改进网络结构、损失函数、数据增强和集成策略，对提升模型在 HUST-LBEW 数据集 Task 1 上的分类性能。从 v1 的 $F1=0.7209$ 到 v3 的 $F1=0.7921$ ，再到推理优化后的 $F1=0.8170$ ，性能提升幅度约 0.096。

（2）不同版本在不同指标上各有优势：v3b 的召回率最高（0.8181），v3 的精确率最高（0.7973），v2 的 AUC 最高（0.8052）。实际应用中应根据具体需求（是否容忍漏检或误检）选择合适的版本和阈值。

9.2 后续工作展望

当然本文也还有一些做得不够好的地方，后面如果想继续做的话，可以从这几个方向入手：（1）增加 v3 的 fold 和 seed 数量，提供更多模型多样性，降低集成方差；（2）引入端到端的图像级训练，使用 CNN 或 Vision Transformer 自动学习特征，避免手工 LBP 特征在不同检测器下的分布不一致问题；（3）探索更先进的时序建模方法，如 Temporal Convolutional Networks (TCN)、Mamba 等。

参考文献

- [1] Gan J, Zeng W, Xiao Y, et al. DeFB: Decomposed Feature Learning for Real-Time Multi-Person Eyeblink Detection in Untrimmed In-the-Wild Videos. AAAI 2026.
- [2] Jocher G, Chaurasia A, Qiu J. Ultralytics YOLOv8. 2023.
<https://github.com/ultralytics/ultralytics>
- [3] Lv W, Xu S, Zhao Y, et al. RT-DETRv2: Improved Baseline with Bag-of-Freebies for Real-Time Detection Transformer. 2024.
- [4] Lugaresi C, Tang J, Nash H, et al. MediaPipe: A Framework for Building Perception Pipelines. arXiv:1906.08172, 2019.
- [5] Zeng W, Xiao Y, Wei S, et al. Real-time Multi-person Eyeblink Detection in the Wild for Untrimmed Video. CVPR 2023.
- [6] Wu W, Qian C, Yang S, et al. Look at Boundary: A Boundary-Aware Face Alignment Algorithm. CVPR 2018. (WFLW Dataset)
- [7] Lin T Y, Dollár P, Girshick R, et al. Feature Pyramid Networks for Object Detection. CVPR 2017.
- [8] Zhang H, Cisse M, Dauphin Y N, et al. mixup: Beyond Empirical Risk Minimization. ICLR 2018.
- [1] Redmon J, Divvala S, Girshick R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 779-788.
- [2] Jocher G, Chaurasia A, Qiu J. YOLOv8: Ultralytics YOLOv8 Documentation[EB/OL]. <https://docs.ultralytics.com>, 2023.
- [3] Viola P, Jones M. Rapid Object Detection using a Boosted Cascade of Simple Features[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2001.
- [4] Ren S, He K, Girshick R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]. Advances in Neural Information Processing Systems (NeurIPS), 2015: 91-99.
- [5] Liu W, Anguelov D, Erhan D, et al. SSD: Single Shot MultiBox Detector[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2016: 21-37.
- [6] Redmon J, Farhadi A. YOLOv3: An Incremental Improvement[EB/OL]. arXiv:1804.02767, 2018.

- [7] Keskar N S, Mudigere D, Nocedal J, et al. On Large-Batch Training for Deep Learning: Generalization Gap and Sharp Minima[C]. International Conference on Learning Representations (ICLR), 2017.
- [8] Bottou L, Bousquet O. The Tradeoffs of Large Scale Learning[C]. Advances in Neural Information Processing Systems (NeurIPS), 2008: 161-168.
- [9] Li X, Wang Y, Zhang H, et al. Driver Fatigue Detection Based on Improved YOLOv5[C]. Proceedings of the International Conference on Image Processing (ICIP), 2022.
- [10] Zhang T, Liu S, Chen R. Multi-scale Eye Detection Method Based on YOLOv7[J]. Pattern Recognition and Artificial Intelligence, 2023, 36(5): 442-451.
- [11] Ultralytics. YOLOv8 Documentation: Hyperparameter Tuning[EB/OL]. <https://docs.ultralytics.com/guides/hyperparameter-tuning/>, 2024.
- [12] Wang C Y, Bochkovskiy A, Liao H Y M. YOLOv7: Trainable Bag-of-Freebies Sets New State-of-the-Art for Real-Time Object Detectors[C]. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2023: 7464-7475.
- [13] Ge Z, Liu S, Wang F, et al. YOLOX: Exceeding YOLO Series in 2021[EB/OL]. arXiv:2107.08430, 2021.
- [14] Zheng Z, Wang P, Liu W, et al. Distance-IoU Loss: Faster and Better Learning for Bounding Box Regression[C]. Proceedings of the AAAI Conference on Artificial Intelligence, 2020: 12993-13000.
- [15] Lin T Y, Maire M, Belongie S, et al. Microsoft COCO: Common Objects in Context[C]. Proceedings of the European Conference on Computer Vision (ECCV), 2014: 740-755.
- [16] Smith L N. Cyclical Learning Rates for Training Neural Networks[C]. IEEE Winter Conference on Applications of Computer Vision (WACV), 2017: 464-472.
- [17] Loshchilov I, Hutter F. SGDR: Stochastic Gradient Descent with Warm Restarts[C]. International Conference on Learning Representations (ICLR), 2017.
- [18] Zhang H, Cisse M, Dauphin Y N, et al. Mixup: Beyond Empirical Risk Minimization[C]. International Conference on Learning Representations (ICLR), 2018.
- [19] Wang C Y, Liao H Y M, Wu Y H, et al. CSPNet: A New Backbone that can Enhance Learning Capability of CNN[C]. IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2020.
- [20] 华中科技大学. HUST-LBEW: Long-term Blink, Eye and Watch Dataset[DS]. 2022.

Soukupova T, Cech J. Eye blink detection using facial landmarks[C]//21st Computer Vision Winter Workshop. 2016: 1-8.

Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces[J]. arXiv preprint arXiv:2312.00752, 2023.

Zhu L, Liao B, Zhang Q, et al. Vision mamba: Efficient visual representation learning with bidirectional state space model[J]. arXiv preprint arXiv:2401.09417, 2024.

Ma N, Zhang X, Zheng H T, et al. Shufflenet v2: Practical guidelines for efficient cnn architecture design[C]//Proceedings of the European Conference on Computer Vision (ECCV). 2018: 116-131.

Tran D, Bourdev L, Fergus R, et al. Learning spatiotemporal features with 3d convolutional networks[C]//Proceedings of the IEEE International Conference on Computer Vision (ICCV). 2015: 4489-4497.

Carreira J, Zisserman A. Quo vadis, action recognition? a new model and the kinetics dataset[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 6299-6308.

He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778.

Ren H, Xiong Z, Xu H, et al. Proposal-based multiple instance learning for weakly-supervised temporal action localization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2023: 18423-18432.

Gu A, Goel K, Re C. Efficiently modeling long sequences with structured state spaces[C]//International Conference on Learning Representations (ICLR). 2022.

Dao T, Fu D Y, Ermon S, et al. FlashAttention: Fast and memory-efficient exact attention with IO-awareness[J]. Advances in Neural Information Processing Systems (NeurIPS), 2022, 35: 16344-16359.

Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems (NeurIPS). 2017: 5998-6008.

Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//International Conference on Learning Representations (ICLR). 2021.

- Bertasius G, Wang H, Torresani L. Is space-time attention all you need for video understanding?[C]//Proceedings of the International Conference on Machine Learning (ICML). 2021: 813-823.
- Lea C, Flynn M D, Vidal R, et al. Temporal convolutional networks for action segmentation and detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 156-165.
- Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2015: 1-9.
- Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
- Huang G, Liu Z, Van Der Maaten L, et al. Densely connected convolutional networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2017: 4700-4708.
- Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International Conference on Machine Learning (ICML). 2015: 448-456.
- Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: A simple way to prevent neural networks from overfitting[J]. Journal of Machine Learning Research (JMLR), 2014, 15(1): 1929-1958.
- Li Y, Wang S, Tian Q. Eye blink detection based on eye aspect ratio and optical flow[J]. IEEE Access, 2020, 8: 186331-186339.
- Liu W, Wen Y, Yu Z, et al. SphereFace: Deep hypersphere embedding for face recognition[C]//CVPR. 2017: 212-220.
- Szegedy C, Vanhoucke V, Ioffe S, et al. Rethinking the inception architecture for computer vision[C]//CVPR. 2016: 2818-2826.
- Lin T Y, Goyal P, Girshick R, et al. Focal loss for dense object detection[C]//ICCV. 2017: 2980-2988.
- Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[C]//NeurIPS. 2017: 5998-6008.
- Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv:2010.11929, 2020.
- Pan G, Sun L, Wu Z, et al. Eyeblink-based anti-spoofing in face recognition from a generic webcam[C]//ICCV. 2007: 1-8.

- Song X, Zhao X, Duan Z, et al. Towards real-time eyeblink detection in the wild: Dataset, theory and practices[J]. IEEE TIFS, 2020, 15: 2331-2343.
- He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//CVPR. 2016: 770-778.
- Loshchilov I, Hutter F. Decoupled weight decay regularization[J]. arXiv:1711.05101, 2017.
- Guo C, Pleiss G, Sun Y, et al. On calibration of modern neural networks: Confidence and accuracy[C]//ICML. 2017: 1321-1330.